

Opłacalność ekonomiczna i kreacja wartości w systemach Human-AI In-The-Loop

Abstrakt i słowa kluczowe

Tło. Systemy typu *Human-AI In-The-Loop* (HITL) to konfiguracje, w których człowiek pozostaje aktywnym elementem pętli decyzyjnej/produkcyjnej: inicjuje, nadzoruje, weryfikuje, koryguje lub ostatecznie zatwierdza wynik pracy części AI. W praktyce takie układy są coraz częściej wymagane regulacyjnie i organizacyjnie (np. dla systemów wysokiego ryzyka), ale ich **opłacalność** jest nieoczywista: koszty nadzoru mogą „zjeść” zyski z automatyzacji. ¹

Cel. Zsyntetyzować, w stylu naukowego przeglądu, **metody** mierzenia opłacalności i wartości dodanej w HITL oraz **dowody empiryczne** (produktywność, jakość, ryzyko), a także wskazać warunki brzegowe, w których współpraca człowiek-AI jest ekonomicznie uzasadniona.

Metody. Najpierw przeanalizowano trzy wskazane repozytoria GitHub (glitchlab, sbom, swarm) oraz repozytorium *writeups* (katalog [badania/](#)) jako źródła pierwotne projektowych „wzorów pętli” i metryk. Następnie przeprowadzono przegląd literatury akademickiej i źródeł instytucjonalnych (m.in. badania terenowe/eksperymenty RCT, przeglądy ekonomiczne w medycynie, ramy zarządzania ryzykiem i nadzoru człowieka). ²

Wyniki. (i) Ekonomiczna wartość HITL pojawia się najczęściej jako kombinacja *skrócenia cyklu pracy*, *podniesienia jakości* i/lub *redukcji kosztu błędu* — ale silnie zależy od doboru zadań (tzw. „ścięta” granica kompetencji AI). ³ (ii) Najbardziej powtarzalny wzorzec opłacalności to **triage**: AI obsługuje „długiego ogona” działań niskiego ryzyka, a człowiek przejmuje przypadki trudne/wysokiego ryzyka oraz losową kontrolę jakości. ⁴ (iii) Koszt nadzoru bywa nieliniowy: zjawiska takie jak *automation bias* lub „nadmierna weryfikacja” mogą obniżyć jakość i wydłużać czas, dlatego projekt interfejsu i procedur jest kluczowy. ⁵

Wnioski. HITL jest ekonomicznie racjonalny, gdy (1) koszt błędu jest istotny, (2) AI ma wysoką użyteczność w *typowych przypadkach*, (3) istnieje możliwość taniej i mierzalnej kontroli jakości (progi, bramki, sampling), oraz (4) pętla jest instrumentowana metrykami (override rate, czas, błędy) umożliwiającymi iteracyjną optymalizację. ⁶

Słowa kluczowe: Human-AI In-The-Loop; opłacalność; ROI; koszt błędu; triage; automatyzacja wspomagana; bramki jakości; automation bias; aktywne uczenie; governance.

Wprowadzenie

HITL nie jest „częściową automatyzacją” rozumianą intuicyjnie, lecz **konkretną architekturą sterowania**: człowiek jest w pętli jako element decyzyjny (zatwierdza/odrzuca) lub jako element treningowy/jakosciowy (etykietuje, koryguje, dostarcza feedback). W odróżnieniu od *Human-On-The-Loop* (człowiek głównie monitoruje) oraz *Human-Out-Of-The-Loop* (system działa autonomicznie), HITL zakłada, że decyzja/artefakt końcowy przechodzi przez interakcję z człowiekiem w trakcie procesu. ⁷

Z perspektywy ekonomicznej HITL jest próbą pogodzenia dwóch sił: - **wartości automatyzacji** (szybkość, skalowalność, spójność, niższy koszt krańcowy), - **wartości człowieka** (kontekst, odpowiedzialność, zdolność do wykrycia anomalii i ryzyk, kreatywność, interpretacja wieloznaczności).

8

Jednocześnie w wielu domenach europejskich HITL staje się elementem kosztów „nie do uniknięcia” z powodów regulacyjnych. Przykładowo, `entity["organization","Unia Europejska","supranational union"]` w Akcie o sztucznej inteligencji (AI Act) wymaga, aby systemy wysokiego ryzyka były projektowane tak, by mogły być skutecznie nadzorowane przez osoby fizyczne, z uwzględnieniem ryzyk i tendencji do nadmiernego polegania na automatyzacji (automation bias), a w pewnych klasach zastosowań przewiduje nawet wymóg niezależnej weryfikacji przez co najmniej dwie osoby. 9

W konsekwencji „czy HITL ma sens?” często przechodzi w pytanie bardziej inżyniersko-ekonomiczne: **jaki rodzaj HITL** (jak głęboki nadzór, jak często, jak mierzyć) daje najlepszy kompromis koszt-ryzyko-wartość.

Analiza źródeł DonkeyJLove

Repozytoria glitchlab, sbom, swarm: wzorce mierzalnej pętli i kosztów

glitchlab opisuje się wprost jako platforma *Human-AI do generatywnego rozwoju oprogramowania*, oparta o ideę „pętli” prowadzącej do artefaktu oraz separacji odpowiedzialności między warstwami (kontekst → delta → walidacja). Kluczowe dla opłacalności są tu motywy: (a) redukcja kosztu kontekstu poprzez *delta-first / minimal context*, (b) progi „go/no-go” (gating) i *szybkie walidacje*, które ograniczają koszt błędnych iteracji, oraz (c) nacisk na obserwowalność procesu (metryki i artefakty pętli).

W repo widoczny jest też przykład „mini-kampanii badawczej” (benchmark protokołów kontekstu), gdzie zdefiniowano metryki funkcjonalne (np. `pass_at_1`) oraz metryki jakości reprezentacji/struktury kontekstu (np. `align`, `cr_ast`), a także regułę werdyktu rozstrzygającą wynik najpierw po funkcjonalności, potem po jakości i dopiero na końcu po koszcie czasowym. To jest istotne ekonomicznie, bo modeluje **hierarchię wartości**: najpierw minimalizujemy ryzyko funkcjonalne, potem maksymalizujemy jakość (która przekłada się na koszt poprawek i utrzymania), a dopiero potem optymalizujemy czas.

sbom to laboratorium DevSecOps, zbudowane eksplicitnie w duchu „pomiar → próg → decyzja”, gdzie pipeline generuje zdarzenia (SBOM, skan, delta, gate) i umożliwia analitykę trendów ryzyka oraz bramki decyzyjne w CI/CD. W kontekście HITL szczególnie ważne są: (a) koncept bramek (quality gates) oraz kalibracji progu (np. tryb „warn-only” w fazie pilotażu), (b) ścieżka wyjątków (allowlist/akceptacja ryzyka), oraz (c) postulat domykania pętli do organizacji (np. integracje ticketowe). To jest „HITL w bezpieczeństwie”: automatyczne wykrywanie + decyzja/progi+wyjątki zarządzane przez ludzi.

swarm przedstawia architekturę systemu telemetrycznego dla floty dronów w klastrze Kubernetes, gdzie AI jest osobnym serwisem predykcyjnym. Repo nie opisuje wprost nadzoru człowieka, ale jest reprezentatywne dla klasy systemów cyber-fizycznych, w których (1) koszt awarii bywa bardzo wysoki (bezpieczeństwo, reputacja, przestoje), (2) infrastrukturalny TCO (monitoring, bezpieczeństwo, sieć serwisowa) nie jest pomijalny, a więc opłacalność AI zależy od skali i jakości obserwowalności, oraz (3) decyzje „stop/override” są naturalnym miejscem na HITL.

Katalog `writeups/badania`: archiwum notatek i prac badawczych

W repozytorium *writeups* istnieje katalog badań, który — zgodnie z Twoją dyspozycją — powinien być traktowany jako „biblioteka robocza” i linkowany w finalnym README.

Link do katalogu (zgodnie z poleceniem):

```
https://github.com/DonkeyJJLove/writeups/tree/master/badania
```

Z poziomu konektora udało się bezpośrednio pobrać co najmniej jeden dokument PDF z tego katalogu (dot. ekonomicznej falsyfikacji modelu „data-only”), co potwierdza, że katalog zawiera materiały stricte ekonomiczne.

Uwaga metodyczna: konektor GitHub zwracał błąd przy próbie listowania zawartości katalogu (ścieżka będąca folderem), przez co w tej iteracji raportu nie da się wiarygodnie i kompletnie zindeksować wszystkich plików z `badania/` wyłącznie konektorem — stąd powyższy link jako punkt wejścia do pełnego spisu.

Google Drive: przeszukanie konektora

Wykonane wyszukiwania w podpiętym konektorze Google Drive (frazy m.in. „HITL”, „pętli AI”, „SBOM”) nie zwróciły wyników, które dałoby się wykorzystać jako źródła pierwotne do tego opracowania (brak trafień).

Metody oceny opłacalności i kreacji wartości

Jednostka analizy: zadanie, proces, portfel ryzyk

W praktyce ekonomika HITL jest najlepiej mierzalna na trzech poziomach:

Poziom zadania. Czy wykonanie pojedynczego zadania (ticket, dokument, klasyfikacja, predykcja) jest szybsze/lepsze? Klasyczne metryki to czas, poprawność/jakość, odsetek zadań ukończonych, liczba iteracji poprawek. ¹⁰

Poziom procesu. Czy cały pipeline ma mniejszy koszt całkowity (np. w CI/CD: mniej incydentów, szybszy MTTR, mniej regresji)? Tu istotne są mechanizmy „pomiar → próg → decyzja”, bo pozwalają łączyć wynik AI z akcją i kosztami.

Poziom portfela ryzyk. W domenach regulowanych opłacalność jest często „ryzyko-skorygowana”: system może być droższy operacyjnie, ale tańszy w oczekiwaniu dzięki redukcji prawdopodobieństwa i skutków szkody (kary, roszczenia, straty reputacyjne). To jest spójne z podejściem ramowym do zarządzania ryzykiem AI, gdzie monitoruje się m.in. częstość override’ów, błędy, skargi i decyzje go/no-go. ¹¹

Funkcja wartości i kosztów w HITL

Najbardziej użyteczny (i dający się implementować) rachunek ekonomiczny HITL rozkłada się na:

Wartość (ΔV): - **Δ Produktywność:** wzrost przepustowości lub spadek czasu per zadanie. ¹²

- **Δ Jakość:** mniej błędów, wyższa ocena ekspertów, mniej reklamacji, lepsza satysfakcja klienta. ¹³

- **Δ Ryzyko:** spadek oczekiwanej straty (np. błąd medyczny, błędna decyzja prawna, luka w supply chain).

¹⁴

Koszty (ΔC): - **koszt AI:** inference (opłaty, GPU), integracja, utrzymanie, monitoring, aktualizacje, bezpieczeństwo, dane;

- **koszt człowieka w pętli:** czas weryfikacji, szkolenia, koszt przełączenia kontekstu, koszty organizacyjne (np. dyżury, eskalacje);

- **koszt governance/compliance:** dokumentacja, audyty, logowanie, procesy, wymagania „human oversight”;

- **koszty niejawne:** błędy eskalowane przez automation bias, spadek jakości przez złe dopasowanie zadań do możliwości AI. ¹⁵

Minimalny zestaw wzorów (w praktyce wdrożeniowej):

$$ROI = (\Delta V - \Delta C) / \Delta C$$

$$NPV = \sum_t (\Delta \text{CashFlow}_t / (1+r)^t) - \text{CAPEX}_0$$

$$EV(\text{ryzyka}) = P(\text{błąd}) * \text{Koszt}(\text{błędu})$$

$$\Delta EV = EV_{\text{before}} - EV_{\text{after}}$$

W HITL najczęściej „twardą” częścią jest oszacowanie **ΔEV** (kosztu błędu) oraz **kosztu nadzoru**; dlatego wzorce z repo typu sbom (zdarzenia, bramki, trendy) i glitchlab (metryki jakości + reguła werdyktu) są praktycznym punktem startu do instrumentacji kosztów.

Instrumentacja i metryki operacyjne

Ramy `entity["organization","NIST","us standards agency"]` w playbooku AI RMF (sekcja „Measure”) wprost rekomendują dokumentowanie i mierzenie nadzoru człowieka poprzez statystyki override’ów, błędów, skarg, czasu reakcji oraz decyzji eskalacyjnych. To jest „most” między governance a ekonomią: bez telemetryki nie da się policzyć ROI ani zidentyfikować, gdzie koszt nadzoru jest za wysoki.

¹¹

W praktyce HITL warto utrzymywać (co najmniej) następujący zestaw wskaźników: - **Override rate** i **acceptance rate** (ile rekomendacji AI jest odrzucanych);

- **czas weryfikacji** per typ przypadku (często rozkład jest dwumodalny: bardzo szybkie akceptacje + bardzo długie „edge cases”);

- **jakość po korekcie** i **koszt poprawek** (ile iteracji, ile „rework”);

- **koszt incydentu** i **częstość incydentów**;

- **dryf** (zmiany w danych/środowisku) i koszt rekalkibracji. ¹⁶

Poniższy schemat pokazuje minimalną pętlę HITL z perspektywy wartości i kosztów (triage + bramka):

flowchart LR

A[Wejście: zgłoszenie / przypadek / dane] --> B[AI: predykcja / propozycja / klasyfikacja]

B --> C{Próg / bramka / niepewność}

```

C --> |niskie ryzyko| D[Automatyczna akcja lub szybka akceptacja]
C --> |wysokie ryzyko / niepewność| E[Człowiek: weryfikacja / korekta]
E --> F[Decyzja końcowa + zapis uzasadnienia]
D --> G[Logi, metryki, koszty, jakość]
F --> G
G --> H[Uczenie/kalibracja + zmiana progów]
H --> B

```

(Analogiczna logika „pomiar → próg → decyzja” jest rdzeniem repo sbom.)

Dowody empiryczne i studia przypadków

Zestawienie porównawcze

Poniższa tabela agreguje *ilościowe* wyniki badań, które najczęściej cytuje się jako dowody wartości ekonomicznej konfiguracji człowiek-AI (z różną głębokością HITL). W każdym przypadku różnica ekonomiczna wynika z innego „nośnika wartości”: czasu, jakości, lub kosztu błędu.

| Domena | Typ pętli HITL | Wynik ilościowy (przykładowy) | Interpretacja ekonomiczna | Ograniczenia transferu |
|-----------------------------------------|--------------------------------------------------------------|-----------------------------------------------------------------------|---------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------|
| Obsługa klienta (chat/call center) | AI podpowiada, człowiek odpowiada i może zignorować sugestię | +14% produktywności średnio; silniejsze efekty u mniej doświadczonych | ROI dominuje przez <i>większą przepustowość i standaryzację dobrych praktyk</i> | Efekt heterogeniczny; możliwe małe/ujemne efekty u najlepszych pracowników ¹⁷ |
| Pisanie profesjonalne | AI generuje szkic, człowiek adaptuje i finalizuje | –40% czasu; +18% jakości | Wartość przez <i>skrócenie czasu</i> przy utrzymaniu/rozwoju jakości | Zadania specyficzne; efekt zależny od umiejętności bazowych ¹⁸ |
| Programowanie (zadania eksperymentalne) | AI proponuje kod, człowiek integruje i poprawia | ok. –56% czasu; większy odsetek ukończeń zadania | ROI przez skrócenie cyklu implementacji; możliwa wartość w onboarding | Wynik z konkretnego eksperymentu i zadania; nie przesądza o jakości kodu długoterminowo ¹⁹ |

| Domena | Typ pętli HITL | Wynik ilościowy (przykładowy) | Interpretacja ekonomiczna | Ograniczenia transferu |
|---------------------------------------------|-------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| Doradztwo (zadania „w granicy kompetencji”) | AI wspiera kreatywność/analitykę, człowiek składa odpowiedź | +12.2% wykonanych zadań; +25.1% szybkości; >40% jakości; poza „granicą” spadek poprawności o 19 pp | HITL daje zysk, jeśli zadanie mieści się w „frontier”; poza nim koszt błędu rośnie | Kluczowe: selekcja zadań i edukacja użytkownika; ryzyko degradacji pracy poza frontier ²⁰ |
| Adnotacja danych (NLP kliniczne) | aktywne uczenie selekcjonuje próbki, człowiek etykietuje | redukcja czasu adnotacji 20.5–30.2% (w badaniu użytkowników) | ROI jako zmniejszenie kosztu danych treningowych | Wymaga modelu kosztu adnotacji; czynniki ludzkie (zmęczenie, jakość adnotacji) ²¹ |
| Adnotacja (kontrprzykład) | aktywne uczenie + HITL | w pewnych warunkach oszczędności „znikają” po uwzględnieniu prawdziwego kosztu pracy | ostrzeżenie: nie każdy HITL redukuje koszt w realu | silna zależność od narzędzia, UI i profilu pracy adnotatora ²² |
| Radiologia (ekonomika AI) | AI jako wsparcie/triage, człowiek finalnie odpowiada | przegląd: możliwe oszczędności do ~242 USD/pacjenta w pewnych zadaniach; w innych wzrost kosztów do ~19 USD/pacjenta | ROI zależy od wolumenu, modelu płatności i jakości (specyficzność) | silnie kontekstowe; wymaga wysokiej jakości i dopasowania do workflow ²³ |

Wykres: porównanie zgłaszanych efektów czasowych

Poniższy wykres zestawia *przybliżone* skrócenie czasu (lub ekwiwalent czasu wynikający ze wzrostu przepustowości) w kilku głośnych badaniach. Zestawienie ma charakter ilustracyjny — wartości pochodzą z różnych domen i nie są wprost porównywalne bez normalizacji kosztu błędu i jakości. ²⁴

```

xychart-beta
  title "Skrócenie czasu dzięki układom człowiek-AI (wybrane badania)"
  x-axis ["Call center (ekwiw.)", "Pisanie", "Kodowanie", "Doradztwo", "Adnotacja"]
  y-axis "Skrócenie czasu (%)" 0 --> 60
  bar [12, 40, 56, 20, 25]

```

Co te wyniki mówią o „kreacji wartości”

Zestawienia empiryczne wskazują kilka stabilnych mechanizmów wartości:

Mechanizm skali i standaryzacji. W call center AI działa jak „kopiarka praktyk” — upowszechnia skuteczne wzorce odpowiedzi, co ekonomicznie szczególnie pomaga pracownikom o niskiej bazie kompetencji, skracając krzywą uczenia. ¹⁷

Mechanizm kompresji pracy szkieletowej. W pisaniu lub zadaniach analitycznych AI przejmuje koszty pierwszej wersji, a człowiek robi *selekcję, korektę, dopasowanie do celu i norm*, co daje duży efekt czasowy bez utraty jakości. ²⁵

Mechanizm triage (selekcja przypadków). W medycynie i innych domenach o wysokim koszcie błędu AI bywa opłacalna, gdy realnie zmniejsza obciążenie człowieka przez przekierowanie uwagi na przypadki trudne — ale tylko jeśli system jest wystarczająco dokładny i włączony w workflow tak, by nie generować kosztu „drugiego kierowcy”. ²⁶

Mechanizm redukcji kosztu danych. W adnotacji danych, aktywne uczenie i modele kosztu adnotacji mogą redukować czas, ale wyniki są mieszane: oszczędności mogą być realne (badania kliniczne), ale mogą też „wyparować”, jeśli narzędzie zwiększa złożoność pracy lub błędnie modeluje koszt jednostkowy adnotacji. ²⁷

Wyzwania i ograniczenia

Koszt nadzoru i zjawiska behawioralne

Regulacje i literatura HCI zwracają uwagę, że nadzór człowieka nie jest „darmowy”. AI Act wprost wskazuje potrzebę projektowania nadzoru tak, by ograniczać ryzyka oraz uświadamiać automation bias, a w niektórych klasach zastosowań wymaga nawet podwójnej weryfikacji ludzkiej, co może istotnie zmieniać rachunek kosztów. ¹

Badania nad automation bias i complacency pokazują, że ludzie potrafią popełniać błędy **pominięcia** (nie reagują, bo system „nie alarmuje”) oraz błędy **komisji** (podążają za rekomendacją mimo sprzecznych sygnałów), a proste szkolenia nie zawsze eliminują problem. To jest bezpośredni kanał kosztowy: wzrost kosztu błędu lub kosztów „naprawy szkód”. ²⁸

Dobór zadań i „granica kompetencji” AI

Dowody z badań terenowych dla pracy wiedzy wskazują na nieciągłość: AI poprawia wyniki dla zadań „wewnątrz” granicy, ale może pogarszać wyniki poza nią. Z punktu widzenia ekonomiki oznacza to, że ROI jest wrażliwe na *taxonomię zadań* (co automatyzujemy, co pozostaje po stronie człowieka) i na edukację użytkownika. ²⁰

Wymóg telemetryki i dokumentacji

Ramy NIST AI RMF traktują dokumentację, monitoring i mierzenie nadzoru jako fundament odpowiedzialnego wdrożenia. Ekonomicznie oznacza to: część wartości HITL jest osiągalna dopiero po poniesieniu kosztu instrumentacji (logi, metryki, ewaluacja), ale bez tego organizacja nie potrafi odróżnić „pozornego ROI” od realnego. ²⁹

Ograniczenia dowodów

Wiele często cytowanych liczb pochodzi z eksperymentów kontrolowanych lub pojedynczych organizacji. Nawet gdy metodologia jest silna (RCT, wdrożenie stopniowane), transfer do innych domen wymaga ostrożności: różne są koszty błędu, presja regulacyjna, jakość danych i kultura pracy. ³⁰

W polskim kontekście dochodzi dodatkowy koszt adaptacji do wymagań regulacyjnych i organizacyjnych związanych z AI Act, co jest komunikowane m.in. przez administrację publiczną (harmonogram wejścia przepisów, zakazy określonych praktyk). ³¹

Wnioski i kierunki dalszych badań

Wnioski syntetyczne

Po pierwsze, HITL jest opłacalny „warunkowo”, a nie „z definicji”. Najbardziej wiarygodne dane wskazują, że duże zyski pojawiają się, gdy człowiek i AI są *komplementarne* (AI skraca szkicowanie i obsługuje typowe przypadki; człowiek interpretuje, nadzoruje i obsługuje anomalie). ¹³

Po drugie, koszt nadzoru jest sterowalny projektowo. Repozytoria typu sbom i glitchlab pokazują praktyczny wzorzec: instrumentuj pętlę, wprowadź progi/bramki, utrzymuj możliwość override, a następnie kalibruj system na podstawie danych o błędach i decyzjach. W ekonomii jest to przejście od „AI jako narzędzie” do „AI jako proces z telemetrią”.

Po trzecie, compliance nie jest tylko kosztem — bywa elementem wartości. W domenach wysokiego ryzyka nadzór człowieka i dokumentacja zmniejszają ryzyko szkody i mogą obniżyć oczekiwane koszty incydentów; jednak narzucają minimalny poziom „tarcia” w procesie, który trzeba uwzględnić w ROI. ³²

Rekomendacje wdrożeniowe

1) **Zaczynaj od triage + bramka, nie od pełnej automatyzacji.** To najczęściej daje dodatni ROI, bo ogranicza koszt błędu i koszt niepewności. ³³

2) **Zaprojektuj metryki zanim wdrożysz model.** Minimum to: czas, jakość, override rate, incydenty, dryf. Wprost rekomenduje to NIST w części „Measure”. ¹¹

3) **Ustal „granicę użycia” i szkol użytkowników.** Wyniki o „jagged frontier” sugerują, że brak takiej granicy generuje koszty degradacji pracy. ²⁰

4) **Traktuj UI/UX jako komponent ekonomiczny.** Jeśli weryfikacja AI jest trudna, ludzie albo będą nadmiernie ufać (ryzyko), albo nadmiernie sprawdzać (koszt czasu). Oba scenariusze obniżają opłacalność. ³⁴

Kierunki dalszych badań

Największe luki w wiedzy (z punktu widzenia ekonomii HITL) dotyczą dziś: - standaryzacji *kosztu nadzoru* (czas, obciążenie poznawcze, błędy behawioralne) jako komponentu TCO; ³⁵

- długookresowych efektów na kompetencje (kto się uczy, kto traci przewagę) i ich wpływu na produktywność organizacji; ³⁶

- porównywalnych, wielośrodkowych analiz ekonomicznych w domenach wysokiego ryzyka (medycyna, administracja, prawo), gdzie regulacje wymuszają szczególne formy human oversight. ³⁷

Referencje źródłowe

- Repozytoria GitHub (źródła pierwotne): glitchlab (architektura pętli, metryki i benchmark), sbom (pomiar-próg-decyzja w DevSecOps), swarm (architektura systemu telemetrycznego + serwis AI).
- AI Act (tekst PL, EUR-Lex) oraz omówienia instytucjonalne (wejście przepisów, kontekst wdrożeniowy w Polsce). ³⁸
- Badania empiryczne produktywności: call center (NBER), pisanie (Science), programowanie (GitHub). ³⁹
- Badanie „jagged technological frontier” (field experiment w pracy wiedzy). ²⁰
- Koszt danych/aktywne uczenie i HITL: MITRE (kontrprzykład), cost-aware AL (PubMed/PMC). ⁴⁰
- Ekonomia AI w radiologii (systematic review). ²³
- Ryzyko błędów i automation bias w HITL (przeglądy i eksperymenty). ²⁸

¹ ⁵ ⁷ ¹⁵ ³³ Article 14: Human oversight | AI Act Service Desk

https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-14?utm_source=chatgpt.com

² ¹² ¹³ ¹⁷ ²⁴ ³⁰ ³⁶ ³⁹ Generative AI at Work | NBER

https://www.nber.org/papers/w31161?utm_source=chatgpt.com

³ ⁸ ²⁰ Ethan Mollick: Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality — Stanford Digital Economy Lab

https://digitaleconomy.stanford.edu/event/ethan-mollick-navigating-the-jagged-technological-frontier-field-experimental-evidence-of-the-effects-of-ai-on-knowledge-worker-productivity-and-quality/?utm_source=chatgpt.com

⁴ ¹⁴ ²³ ²⁶ ³⁷ Economic Value of AI in Radiology: A Systematic Review - PubMed

https://pubmed.ncbi.nlm.nih.gov/41258794/?utm_source=chatgpt.com

⁶ ¹¹ ¹⁶ ²⁹ Measure - AIRC

https://airc.nist.gov/airmf-resources/playbook/measure/?utm_source=chatgpt.com

⁹ ³² ³⁸ Rozporządzenie - UE - 2024/1689 - DE - EUR-Lex

https://eur-lex.europa.eu/eli/reg/2024/1689/oj/pol?utm_source=chatgpt.com

¹⁰ ¹⁸ ²⁵ Experimental evidence on the productivity effects of generative artificial intelligence | SCALE Initiative

https://scale.stanford.edu/publications/experimental-evidence-productivity-effects-generative-artificial-intelligence?utm_source=chatgpt.com

¹⁹ Research: quantifying GitHub Copilot's impact on developer productivity and happiness - The GitHub Blog

https://github.blog/2022-09-07-research-quantifying-github-copilots-impact-on-developer-productivity-and-happiness/?utm_source=chatgpt.com

²¹ ²⁷ Cost-aware active learning for named entity recognition in clinical text - PubMed

https://pubmed.ncbi.nlm.nih.gov/31294792/?utm_source=chatgpt.com

²² ⁴⁰ Active Learning with a Human In The Loop | MITRE

https://www.mitre.org/news-insights/publication/active-learning-human-loop?utm_source=chatgpt.com

²⁸ ³⁴ ³⁵ Complacency and bias in human use of automation: an attentional integration - PubMed

https://pubmed.ncbi.nlm.nih.gov/21077562/?utm_source=chatgpt.com

31 Pierwsze przepisy Rozporządzenia o Sztucznej Inteligencji (AI Act) zaczynają obowiązywać -
Ministerstwo Cyfryzacji - Portal Gov.pl

[https://www.gov.pl/web/cyfryzacja/pierwsze-przepisy-rozporzadzenia-o-sztucznej-inteligencji-ai-act-zaczynaja-obowiazywac?
utm_source=chatgpt.com](https://www.gov.pl/web/cyfryzacja/pierwsze-przepisy-rozporzadzenia-o-sztucznej-inteligencji-ai-act-zaczynaja-obowiazywac?utm_source=chatgpt.com)