

# Ryzyka i złożoność w SaaS+AI: synteza Twoich repozytoriów i badań z oceną mediów oraz obserwatorów

## Zakres materiału i metoda

Analiza łączy dwa strumienie dowodowe.

Pierwszy strumień to Twoje repozytoria GitHub, które przejrzałem w kolejności wskazanej w poleceniu (konektor GitHub): `sbom`, `writeups`, `chunk-chunk`, `swarm`, `ai_platform`, `HA2D`. W nich szukałem nie „ładnych idei”, tylko miejsc, gdzie system faktycznie **zamyka pętlę sterowania** (pomiar → próg → decyzja → konsekwencja) oraz gdzie w kodzie pojawiają się praktyczne odpowiedniki problemów, o których mówi rynek: koszty zmienne, ryzyko kaskad, zawodność, bezpieczeństwo, audytowalność, integracje i lock-in.

Drugi strumień to „ocena z zewnątrz”: możliwie świeże (na dziś, 10 lutego 2026) sygnały rynkowo-medialne o SaaS+AI (zwłaszcza lutowe materiały 2026 o „AI-disruption”), a także źródła normatywne i techniczne (regulacje UE, standardy bezpieczeństwa AI, SRE, FinOps/FOCUS, IEA). W tym strumieniu priorytet dałem źródłom pierwotnym i oficjalnym oraz – gdzie to możliwe – źródłom polskim.

Punkt ciężkości raportu jest analityczny: nie chodzi o streszczenie repozytoriów ani przegląd prasy, tylko o ich **konfrontację**: (a) czy Twoje artefakty rzeczywiście „widzą” to, co media i obserwatorzy uznają dziś za główne ryzyka SaaS+AI, (b) gdzie są luki i niespójności, (c) jakie działania techniczne i komunikacyjne domkną całość.

## Co media i obserwatorzy uznają dziś za główne problemy SaaS+AI

Najbardziej „twardym” sygnałem z początku 2026 jest to, że dyskusja o AI w SaaS przestała dotyczyć tylko produktywności, a zaczęła dotyczyć **egzystencjalnej przebudowy modeli biznesowych** i ryzyk systemowych.

W dniach 9–10 lutego 2026 `Entity["organization","Reuters","news agency, global"]` opisywał falę globalnej wyprzedaży akcji spółek software/services, wywołaną obawą, że szybko dojrzewające narzędzia agentowe mogą „ominąć” tradycyjne modele oprogramowania i usług (katalizatorem miał być nowy produkt prawny/„legal tool” od `Entity["company","Anthropic","ai company, claude"]`). W relacji z 9 lutego 2026 pada teza o rynkowym „wake-up call”: inwestorzy zaczęli wyceniać scenariusz, w którym część SaaS przestaje być „maszyną do powtarzalnych przychodów”, bo AI skraca dystans między potrzebą a wynikiem (a więc podważa wartość warstw pośrednich). <sup>1</sup> Jednocześnie w dniu 10 lutego 2026 `Entity["company","Morgan Stanley","investment bank"]` ostrzegał, że to nie jest tylko historia o akcjach: jeżeli AI realnie obniży marże i stabilność spółek software, może to przełożyć się na rynek kredytowy (m.in. z powodu koncentracji ryzyka w segmencie nisko-ratingowych pożyczek dla firm software). <sup>2</sup>

Medialnie to spina się z dwoma „bardziej długimi” problemami, które w 2024–2026 stale wracają:

Po pierwsze: **pricing i telemetria**. [Entity["organization","Bain & Company","management consulting firm"]] opisuje, że AI wzmacnia rozjazd między „per-seat” (łatwe do sprzedania i prognozowania) a rzeczywistą strukturą kosztu i wartości AI, gdzie koszty inferencji/fine-tuning/R&D są zmienne i często nie mają prostego licznika „na użytkownika”. Wątek kluczowy to trudność przejścia na modele hybrydowe/usage/outcome ze względu na brak telemetrii produktu i infrastruktury billingowej, a także reorganizację sprzedaży i finansów. <sup>3</sup> W praktyce oznacza to, że „nowy pricing” jest problemem **architektury danych i kontroli**, a nie tylko marketingu.

Po drugie: **koszt zmienny i „whales”**. [Entity["organization","Business Insider","digital news outlet"]] opisał w 2025 mechanikę „inference whales”: ciężcy użytkownicy potrafią konsumować zasoby obliczeniowe o rząd wielkości większe niż wpłacany abonament, co zmusza dostawców do limitów i przejścia na usage-based (lub przynajmniej capów). <sup>4</sup> To nie jest detal: to mechanizm, który uczy rynek, że agentowe workflow’y (wiele kroków, dużo tokenów, retrievery, iteracje) zachowują się jak **złośliwy test obciążeniowy** wbudowany w produkt.

Na to nakłada się warstwa infrastrukturalno-energetyczna: [Entity["organization","International Energy Agency","intergovernmental energy org"]] prognozuje, że globalne zużycie energii przez data centers ma wzrosnąć do ok. 945 TWh do 2030 (w scenariuszu bazowym), a udział serwerów „accelerated” (napędzanych głównie przez AI) ma być dominujący w przyroście. <sup>5</sup> Ten sam raport był szeroko komentowany medialnie (w tym Reuters). <sup>6</sup> W praktyce oznacza to, że „skalowalność SaaS+AI” ma dzisiaj ograniczenia nie tylko software’owe, ale też energetyczno-sieciowe (czas budowy DC vs lead time energii). <sup>5</sup>

Trzeci filar obserwacji z zewnątrz dotyczy bezpieczeństwa i regulacji.

Z perspektywy security, [Entity["organization","OWASP Foundation","security nonprofit"]] w Top 10 dla aplikacji LLM (v1.1) formalizuje ryzyka, które dobrze mapują się na SaaS: prompt injection, insecure output handling, poisoning, model DoS (czyli i awarie, i spirale kosztów), supply chain vulnerabilities, disclosure. <sup>7</sup> To jest ważne w Twoim kontekście, bo część Twoich repozytoriów wprost buduje „pętle sterowania” – a OWASP mówi, gdzie te pętle realnie są atakowane (wejście/wyjście modelu, koszty, łańcuch dostaw danych i komponentów).

Z perspektywy governance i etyki (w praktyce: zarządzania ryzykiem), [Entity["organization","NIST","us standards institute"]] publikuje AI RMF 1.0 jako ramę „Govern/Map/Measure/Manage”; to jest język, którym instytucje i enterprise próbują uczynić AI audytowalnym i sterowalnym. <sup>8</sup> Dla generatywnej AI istnieje też profil towarzyszący (który doprecyzowuje typowe ryzyka i praktyki). <sup>9</sup>

Wreszcie: Unia Europejska. W AI Act mocno wybrzmiewa wątek śledzenia zachowania systemu w czasie (logi, dokumentacja techniczna, post-market monitoring). W samym tekście aktu oraz w narzędziach Komisji widać nacisk na systemowe monitorowanie „w całym cyklu życia”, z planem monitoringu jako częścią dokumentacji (dla high-risk). <sup>10</sup> To jest regulacyjny odpowiednik Twojej tezy „pętla sterowania musi być domknięta”.

Równolegle Data Act wprowadza zmianę w tle ekonomii cloud/SaaS: ma usuwać bariery zmiany dostawcy, w tym stopniowe wycofanie opłat za switching i egress do 12 stycznia 2027. <sup>11</sup> To nie usuwa lock-inu w sensie architektury, ale osłabia jeden z jego najprostszych „fizycznych” mechanizmów (opłaty za transfer). To ważne, bo przesuwa nacisk z lock-inu „cenowego” na lock-in „systemowy” (integracje, formaty, procesy, model governance).

## Co Twoje repozytoria robią z problemem złożoności i gdzie „dotykają” SaaS+AI

Twoje repozytoria nie wyglądają jak klasyczny „produkt SaaS”, tylko jak zestaw **artefaktów sterowania złożonością**: narzędzia bezpieczeństwa łańcucha dostaw, polityki odporności sieciowej, protokoły kontekstu, warstwa ontologiczna (9D) i meta-dokumenty o prawdzie/fikcji w LLM. To jest istotne: w świecie SaaS+AI największe awarie rzadko pochodzą z jednego błędu; częściej są skutkiem **kaskady w złożonym układzie** (sprzężenia, progi, opóźnienia, błędnie ustawione liczniki, brak bariery).

Najbardziej „inżyniersko twardy” element sterowania widzę w `sbom` – szczególnie w pipeline Jenkins (`lab/jenkins/pipeline_one.pipeline`). To jest bardzo czytelny, zamknięty mechanizm cybernetyczny:

- pipeline wymusza stabilność wykonania (np. `disableConcurrentBuilds()` i „przetrawianie” `durabilityHint('MAX_SURVIVABILITY')`), co jest sygnałem, że traktujesz to jako element infrastruktury sterowania, a nie jednorazowy skrypt;
- generujesz SBOM CycloneDX (`syft`) i skan (`grype`) wewnątrz kontenera toolbox;
- wyciągasz snapshot komponentów do porównania, pobierasz poprzedni snapshot z Elastic, liczysz deltę, a potem przechodzisz przez bramkę decyzyjną (`FAIL_ON ∈ {none, critical, high}`), która może unieruchomić wydanie (exit 10). To jest wprost „pomiar → próg → akcja”. W samym pipeline widać też ustandaryzowany identyfikator AID (`env/app/version/repo/vcs_ref`), co jest załącznikiem „metryki porównywalnej w czasie” – bez tego nie ma post-market monitoringu.

Ważny detal: pipeline wysyła do Elastic nie jeden event, ale **rodzinę zdarzeń** (`sbom_snapshot`, `sbom_scan`, `delta`, `gate`). To jest de facto prosty event-sourcing dla ryzyka supply chain – i w praktyce daje Ci funkcję „pamięci” (historia) oraz „stanu” (ostatni snapshot).

W Twojej dokumentacji `sbom` pojawia się też warstwa conceptualna: SBOM jako marker strukturalny oraz dopięcie kryptografii i dowodu pochodzenia do pętli DevSecOps; kluczowe jest, że wartość SBOM ujawnia się dopiero, gdy przestaje być „dokumentem”, a staje się elementem sterowania (progi kompozycji/podatności/zaufania). To jest spójne z obserwacją, że w AI-SaaS kończy się świat „raportów”, a zaczyna świat „gatingu”.

Drugi filar „zderzenia z realnością SaaS” to `swarm`, gdzie masz polityki odporności w warstwie mesh: `EnvoyFilter` do rate limiting i `DestinationRule` do circuit breaking/outlier detection. W `rate-limit.yaml` ustawiasz `failure_mode_deny: true` i timeout na 0.25s dla zewnętrznej usługi limitującej. Semantyka `failure_mode_deny` w Envoy jest fundamentalna: to wybór „fail closed”, czyli w razie problemów z usługą rate-limit proxy ma nie przepuszczać ruchu.<sup>12</sup> To jest bardzo mocna decyzja architektoniczna: w świecie AI (koszt na request, ryzyko przeciążenia, „whales”) fail-open często oznacza spiralę kosztów i awarię.

W `circuit-breaker.yaml` stosujesz outlier detection (5xx errors, interval 1s, ejection 30s, ejection up to 100%). Mechanika outlier detection (kiedy host wypada z puli, jak długo, jaki procent) jest standardowo opisana w dokumentacji service mesh.<sup>13</sup> W ujęciu SRE to jest element „odcięcia kaskady”: izolujesz źle działający upstream, żeby nie zatruł całego systemu.

Tutaj Twoje repo dotyka tego, co Google opisuje jako redukcję kaskad: najczęstszy powód cascading failures to **overload**, a skuteczną bronią jest load shedding i kontrola kolejek/limitów.<sup>14</sup> Zwracam uwagę: Twoje mesh-policies są wprost implementacją tej logiki, tylko na poziomie gateway/upstream.

Jednocześnie `swarm` pokazuje też „ciemną stronę” złożoności, która jest szczególnie ważna w SaaS+AI: łatwo zbudować kontrolę na brzegu (mesh), ale mieć podatne elementy w środku. Przykład: `aggregator/aggregator.py` tworzy nowy wątek dla *każdego* pakietu UDP i wysyła request HTTP bez jawnego timeoutu; w warunkach bursta to może być wektor przeciążenia i degradacji (czyli dokładnie to, co SRE identyfikuje jako początek kaskady).<sup>14</sup> Jeśli do tego dołożysz AI-komponenty, analogiczny pattern („jeden request → wiele kroków agentowych”) jest definicją cost explosion.

Trzeci filar to `HA2D`, czyli protokół kontekstu i kontrola integralności pamięci (UUID + SHA256, timestamp, operacje store/retrieve/latest). To jest „mini-system audytu” dla stanu kontekstowego: umożliwia wykrywanie naruszeń integralności i daje ślad w czasie. To ma bezpośrednie przełożenie na wymogi audytowalności (AI Act naciska na logi i monitoring cyklu życia)<sup>15</sup> oraz na praktykę bezpieczeństwa (WORM-like myślenie o dowodzie).

Czwarty filar to `chunk-chunk`, gdzie w protokole HMK9D formalizujesz kontrakt  $H(s)=g(F(s))$ , ryzyko  $R(F,g)$  i „energię” jako koszt lokalny oraz globalny, a także bramki (Próg-Przejsię) i „energy\_guard” w procesach. To jest w istocie język kontroli złożoności: zamiast mówić „system jest skomplikowany”, opisujesz go jako serię kroków  $\Delta$ , gdzie każdy ma koszt i wektor w przestrzeni osi (9D). W praktyce to jest Twoja własna wersja tego, co teoria systemów nazywa pracą na sprzężeniach i progach.

Piąty filar to `ai_platform`, w którym próbujesz zmapować heterogeniczny ekosystem repozytoriów i artefaktów na spójny rejestr współrzędnych (`/QV9D`). To jest podejście do złożoności organizacyjnej: zamiast „kolejnych folderów i wiki”, masz ambicję uzyskać **odwracalne mapowanie** między warstwą semantyczną a kodem. Jednocześnie w samym specyfikowaniu algorytmu mapowania pojawia się jawnie niezidentyfikowany element („DO ZAPROJEKTOWANIA”: sposób deterministycznego ID). To warto potraktować jako sygnał: rdzeń konceptu jest gotowy, ale „mechanika dowodu i spójności” nadal jest ryzykiem.

Szósty filar to `writeups`: tutaj powstaje warstwa epistemiczna (prawda vs fikcja, protokoły kontekstu, „mikrokod”, P0-P3, itd.). W kontekście SaaS+AI jest to potencjalnie najbardziej niedoceniany element: jeśli system generuje język, który uruchamia działanie (narzędzia, commit, API), to różnica między „ładną narracją” a „weryfikowalnym stwierdzeniem” jest różnicą między bezpiecznym systemem a performatywną halucynacją. OWASP nazywa to m.in. insecure output handling i disclosure.<sup>7</sup>

## Konfrontacja z krytyką i aktualną oceną: zgodności, rozbieżności, luki

Twoje repozytoria w dużym stopniu są **zgodne kierunkowo** z tym, co media/obserwatorzy uznają dziś za realne ryzyka SaaS+AI, ale zgodność jest asymetryczna: jesteś bardzo mocny w „sterowaniu strukturą i granicami” (SBOM, progi, mesh-policies, pamięć i log), a relatywnie słabszy w „sterowaniu ekonomią i semantyką wyjścia” (unit economics dla inferencji, telemetria wartości/zużycia w produkcji, polityki output-safety).

### Zgodności wysokiej wagi

Najważniejsza zgodność jest strukturalna: Twoje repozytoria nie traktują AI jako „feature”, tylko jako **układ sprzężeń**, który trzeba zamknąć progami.

To jest dokładnie to, co Twoje wcześniejsze badania nazywają „pętlą w pętli”: gdy rośnie koszt jednostkowy ( $q$ ) i/lub wykorzystanie ( $u$ ), presja rynkowa pcha cenę ( $P$ ), co zmienia zachowanie klientów i może destabilizować marżę. W tej samej pracy masz formalizację progu behawioralnego klienta ( $u^* = P/q$ ) oraz marży  $M = (P - q \cdot u) \cdot S$ , co wprost opisuje, dlaczego „użytkownicy-wieloryby” są problemem: w abonamencie  $P$  jest stałe, a  $q \cdot u$  rośnie. Ta abstrakcja pasuje do zjawiska „inference whales” opisywanego w prasie: heavy usage rozsądza model flat-fee, wymuszając capy/usage-based.

4

Druga zgodność: Twoje narzędzia techniczne są wprost „anty-kaskadowe” (rate limit, circuit breaker, bramki). To jest spójne z klasyczną teorią progów i kaskad: Granovetter pokazał, że rozkład progów może generować drastycznie odmienne wyniki zbiorowe mimo podobnych „średnich” preferencji.<sup>16</sup> Watts formalizował rzadkie, ale ogromne kaskady od małych bodźców w sieciach progowych.<sup>17</sup> W praktyce SaaS+AI oznacza to: drobna zmiana (model, prompt, billing, limit) może uruchomić nieproporcjonalne efekty (koszt, awaria, reputacja, migracje klientów). Twoje repozytoria są zbudowane tak, jakbyś zakładał właśnie tę klasę zjawisk.

Trzecia zgodność: Twój „motyw Manhattan” (superteza) opisuje mechanikę wyścigu i kaskad w warunkach presji czasu i zasobów, ale jednocześnie wskazuje na ryzyko centralizacji decyzji, błędów i kosztów. To jest zgodne z dzisiejszą oceną rynku: Reuters opisuje „przebudzenie”, w którym AI-automatyzacja może szybko przenosić wartość z jednych warstw software do innych, generując gwałtowne repricing (luty 2026).<sup>18</sup>

## Rozbieżności i luki, które stają się ryzykiem

Najbardziej istotne luki grupują się w czterech miejscach.

Pierwsza luka: **telemetria wartości i kosztu „na jednostkę”** w runtime AI. Bain mówi wprost, że przejście do nowych modeli cenowych wymaga telemetrii produktu i infrastruktury billingowej.<sup>3</sup> W Twoim stacku telemetria jest mocna po stronie bezpieczeństwa kompozycji (SBOM/scan/delta/gate), ale słabsza po stronie AI-zużycia: brakuje analogicznego „AID + event types” dla (a) tokenów/sekund inferencji, (b) kosztu per workflow, (c) budżetów per tenant, (d) efektywności (np. cost per resolved ticket / per story point / per case). Bez tego Twoja własna teza ekonomiczna („pętla w pętli”) pozostaje bardziej prorocstwem niż mechanizmem sterowania.

Druga luka: **security specyficzne dla LLM jako komponentu SaaS**. SBOM-moduł dobrze adresuje supply chain w sensie bibliotek/paczek, ale OWASP Top 10 wskazuje specyficzne kategorie dla aplikacji LLM: prompt injection, insecure output handling, model DoS, training data poisoning, disclosure.<sup>7</sup> Mesh-policies pomagają w model DoS (na poziomie transportu), ale nie rozwiązują output-handling (np. „LLM wygenerował payload, który wykonał się w downstream”). Ta luka jest istotna, bo w Twoich writeupach masz silną intuicję „słowo → czyn”, ale w kodzie/konfiguracji brakuje równie twardych „bramek wyjścia” jak w SBOM.

Trzecia luka: **regulacyjny „post-market monitoring” jako proces, nie tylko log**. AI Act (dla high-risk) wymaga systematycznego zbierania i analizy danych o działaniu w całym cyklu życia oraz planu monitoringu jako części dokumentacji.<sup>10</sup> Twoje artefakty (CMM w HA2D, eventy w sbom) są bardzo dobrym budulcem, ale w repozytoriach brakuje „spięcia” w jeden formalny plan: co jest KPI ryzyka, jakie są progi, kto jest właścicielem, jak wygląda eskalacja, jak wygląda analiza interakcji z innymi systemami (wprost wspomniana w akcie).<sup>19</sup>

Czwarta luka: **ryzyko „mnożenia logik” i brak meta-redukcji** w implementacji. Twoja „Teza o mnożeniu logik” mówi, że do kaskad prowadzi multiplikacja warstw decyzyjnych i brak nadrzędnego mechanizmu, który redukuje i porządkuje logiki w czasie. Jednocześnie w praktycznych komponentach (np. `swarm` aggregator UDP-threads, brak timeoutów, brak autoryzacji w API) widać miejsca, gdzie logika „systemowa” nie jest jeszcze zredukowana do bezpiecznych prymitywów (kolejka, backpressure, budżet, limit). To jest ryzyko, bo AI-warstwa ma tendencję do dokładania kolejnych pętli (retry, tool-use, multi-agent), co wzmacnia dokładnie tę patologię.

**Regulacje i rynek: gdzie Twoje założenia są trafne, a gdzie trzeba je zaktualizować**

Twoje badania o lock-inie cenowym i mechanice egress są trafne jako opis przeszłości i bieżącej praktyki rynkowej, ale Data Act zmienia parametry gry: od 12 stycznia 2027 ma zniknąć możliwość pobierania opłat za switching i egress jako bariery migracji. <sup>11</sup> Twoje wcześniejsze ujęcie, że dostawcy „podnoszą opłaty lock-in” i że egress staje się bronią, pozostaje prawdziwe opisowo dla epoki przed pełnym wejściem Data Act. Natomiast strategicznie oznacza to, że lock-in przesunie się w stronę: kompatybilności, specyficznych API, formatów semantycznych, „kultury procesu”, oraz (w AI) lock-inu wynikającego z danych i dopasowania modeli.

To paradoksalnie wzmacnia sens Twojego podejścia do „mapowania ontologii” (QV9D) i do protokołów kontekstu: jeżeli bariery finansowe migracji maleją, rośnie waga barier semantycznych i procesowych.

**Tabela porównawcza: fragmenty kodu/dokumentacji vs. oceny mediów i obserwatorów**

Fragment (repo / ścieżka)	Co faktycznie robi (skrót techniczny)	Jaki problem SaaS+AI adresuje	Co mówią media/ obserwatorzy (najnowsze)	Ocena zgodności i ryzyko
<code>sbom/lab/jenkins/pipeline_one.pipeline</code>	SBOM+scan, delta względem poprzedniego snapshotu, gate ( <code>FAIL_ON</code> ) i blokada wydania	Sterowalność ryzyka supply chain; twarde progi („fail pipeline”)	Rynek mówi: potrzebne nowe progi i telemetria, bo AI burzy stabilność modeli (luty 2026, Reuters) <sup>1</sup>	<b>Wysoka zgodność.</b> Ryzyko: obejmuje software dependencies, nie model/dane.
<code>sbom/.../pipeline_one.pipeline</code> (event types)	<code>sbom_snapshot</code> , <code>sbom</code> , <code>scan</code> , <code>delta</code> , <code>gate</code> w Elastic	Historia, audyt, porównywalność w czasie	AI Act akcentuje logi i monitoring cyklu życia (post-market)	<b>Kierunkowo zgodne</b> , ale brakuje formalnego planu monitoringu.

Fragment (repo / ścieżka)	Co faktycznie robi (skrót techniczny)	Jaki problem SaaS+AI adresuje	Co mówią media/ obserwatorzy (najnowsze)	Ocena zgodności i ryzyko
<code>sbom/kryptologia-informacyjna-sbom.md</code>	Ujęcie: SBOM jako marker + cybernetyka „pomiar→próg→akcja” + dowód pochodzenia	Bezpieczeństwo jako sterowanie, nie raport	NIST AI RMF: Map/ Measure/ Manage jako sterowanie ryzykiem <sup>8</sup>	<b>Silna zgodność</b> (filozofia + praktyka).
<code>swarm/.../rate-limit.yaml</code>	Envoy rate limit, <code>failure_mode_deny: true</code> , timeout 0.25s	Ochrona przed przeciążeniem i spiralką kosztów; fail-closed	OWASP: Model DoS i kosztowe DoS jako typowy wektor <sup>7</sup> ; SRE: overload jako źródło kaskad <sup>14</sup>	<b>Wysoka zgodność.</b> Ryzyko: rate limit service staje się elementem krytycznym (jego awaria = 500). <sup>21</sup>
<code>swarm/.../circuit-breaker.yaml</code>	Outlier detection (ejection) po 5xx	Izolacja awarii upstream; redukcja kaskad	SRE: kaskady i load shedding; outlier jako praktyka „odcinania” awarii <sup>22</sup>	<b>Wysoka zgodność.</b> Ryzyko: agresywność (interval 1s, 100% ejection) może generować false positives przy fluktuacjach.
<code>swarm/aggregator/aggregator.py</code>	Wątek per UDP packet; POST do API bez jawnego timeout; brak backpressure	Ryzyko „wewnętrznego DoS” i kaskady w środku systemu	SRE: overload zwykle zaczyna się od przeciążenia i kolejek; brak limitów pogarsza sytuację <sup>14</sup>	<b>Niezgodność/ ryzyko:</b> komponent podważa intencję mesh-policies.
<code>swarm/aggregator-api/aggregator_api.py</code>	Prosty endpoint do DB bez auth	Ryzyko nadużyć i eksfiltracji	OWASP: disclosure + supply chain + output handling jako klasy ryzyk <sup>7</sup>	<b>Luka bezpieczeństwa</b> (jeśli to ma być SaaS-like).

Fragment (repo / ścieżka)	Co faktycznie robi (skrót techniczny)	Jaki problem SaaS+AI adresuje	Co mówią media/ obserwatorzy (najnowsze)	Ocena zgodności i ryzyko
<code>HA2D/context_protocol.md</code>	Rekordy kontekstu z UUID, timestamp, SHA256; operacje store/retrieve/latest	Integralność pamięci kontekstu; audyt	AI Act: logi i monitoring; NIST: governance i TEVV <sup>23</sup>	<b>Zgodne jako budulec</b> , brak integracji z całościową telemetrią produkcyjną.
<code>chunk-chunk/hmk9d_protocol.yaml</code>	Formalizm $H(s)=g(F(s))$ , ryzyko $R(F,g)$ , energia, bramki	Modelowanie złożoności jako pętli i progów	Teoria progów/kaskad (Granovetter, Watts) pokazuje, że to właściwy język dla rzadkich kaskad <sup>24</sup>	<b>Kierunkowo bardzo silne</b> , ale wymaga „operacjonalizacji” w telemetry/billing/runtime.
<code>ai_platform/platform.md</code>	Mapowanie repo/artefaktów do <code>/QV9D</code> , próba odwracalnej struktury	Zarządzanie złożonością organizacyjną i semantyczną (governance)	FinOps/rynek: rosną koszty i potrzeba spójnego języka wartości; FOCUS jako standaryzacja kosztów <sup>25</sup>	<b>Zgodne jako idea</b> , luka: brak deterministycznych ID i brak spięcia z realnym kosztem.
<code>writeups/...</code> (P0–P3, protokoły kontekstu)	Ramy: prawda vs fikcja, protokół kontekstu, mikrokod	Bezpieczeństwo epistemiczne (redukcja halucynacyjnego sterowania)	OWASP: insecure output handling i prompt injection to realne wektory w SaaS+AI <sup>7</sup>	<b>Zgodne konceptualnie</b> , brak twardych „bramek wyjścia” w kodzie produkcyjnym.

## Luki, niezgodności i ryzyka: diagnoza „gdzie pętle nie są domknięte”

Twoje badania wprost przewidują, że układy SaaS+AI destabilizują się przez sprzężenia: cena–użycie–koszt, progi klienta, progi systemu, „mnożenie logik”, kaskady. Z perspektywy implementacyjnej największe ryzyka to:



Brak ujednoliconej, produkcyjnej telemetrii kosztu i użycia AI. FinOps idzie dziś w stronę rozszerzania scope na AI/SaaS i nacisku na unit economics; FOCUS jest próbą normalizacji danych kosztowych między dostawcami. <sup>26</sup> Jednak w Twoich repozytoriach koszt jest bardziej „modelem” niż instrumentem. To grozi sytuacją, w której mechanizmy ochrony (rate limits, progi) są ustawiane „na czuja”, a nie na podstawie obserwowalnego KPI.

Rozjazd między kontrolą na brzegu a kontrolą w środku. Mesh-policies (fail-closed rate limiting, outlier detection) są dojrzałe i zgodne z SRE, ale komponenty aplikacyjne w `swarm` mają wzorce, które generują przeciążenie (wątek per pakiet, brak backpressure). To jest klasyczna luka, która w systemach złożonych tworzy kaskady: kontrolujesz bramę, ale silnik się przegrzewa od środka. <sup>14</sup>

Brak formalnej warstwy „bramek semantycznych” dla output-driven systems. Twoje writeupy bardzo trafnie opisują, że słowo może stać się czynem, ale OWASP mówi: jeżeli output nie jest traktowany jak dane niebezpieczne, kończy się to exploitami i wyciekiem. <sup>7</sup> W kodzie nie widzę „policy engine”, który wymusza sanity/validation wyjścia modelu (schematy, allow-listy, reguły wykonania narzędzi, sandbox).

Niedomknięty „plan monitoringu” pod AI Act. Masz elementy mechaniki (logi, identyfikatory, historia), ale brak dokumentu operacyjnego: metryki, odpowiedzialności, proces eskalacji, analiza interakcji między systemami (wprost wymagana w monitoringu, gdy relewantna). <sup>19</sup>

## Rekomendacje techniczne i komunikacyjne: konkretne kroki domykające spójność

Poniżej rekomendacje podaję tak, by działały przy nieokreślonym budżecie: zaczynam od rzeczy o wysokiej dźwigni (duży efekt, umiarkowany koszt), potem proponuję warstwę „docelową”.

### Rekomendacje techniczne

Zbuduj „AI-telemetrię” analogiczną do SBOM-telemetrii: event types + historia + progi. W praktyce: stwórz odpowiednik AID dla wywołań AI (tenant, workflow\_id, model\_id, narzędzia, licznik tokenów, czas, koszt). Następnie: (a) łap `delta` w czasie (czy rośnie średni koszt per workflow), (b) przetwarzaj progi i budżety per tenant, (c) materializuj decyzje jako „gates” (throttle, degrade, deny, require human review). To jest bezpośrednio operacjonalizowanie Twojego wzoru  $M = (P - q \cdot u) \cdot S$  i progu `u*`.

Włącz FinOps/FOCUS jako warstwę normalizacji kosztu. Nawet jeśli nie implementujesz pełnego FOCUS od razu, warto przyjąć go jako docelowy schemat danych kosztowych, bo minimalizuje „ręczne ETL” między vendorami i scope’ami (cloud/SaaS/AI). <sup>27</sup> Dla Twojej architektury byłby to naturalny odpowiednik `/QV9D` tyle że dla ekonomii: jeden język danych kosztu.

Uczyń `swarm/aggregator.py` odpornym na overload: backpressure, limity, timeouts. To jest „twarde SRE”: kolejka zamiast wątku per pakiet, limit równoległości, bezwzględne timeouty HTTP, retry z budżetem, a najlepiej mechanizm odrzutu. SRE wprost wskazuje: ograniczaj kolejki i odrzucaj pracę, której nie opłaca się przetwarzać, zanim system wejdzie w spiralę. <sup>14</sup> To jest też obrona przed „agentowym” stylem obciążenia.

Zszyj mesh-policies z metryką ryzyka i kosztu. Dziś rate limit i circuit breaker są „ślepe” na koszt ekonomiczny. Docelowo powinny działać na wielowymiarowych deskryptorach: tenant, plan, typ workflow, „koszt na krok” (Twoja „energia”), ryzyko. To jest praktyczne wdrożenie HMK9D jako runtime-policy.

Dopnij warstwę bezpieczeństwa LLM zgodną z OWASP:

- wejście: anty-prompt-injection (policy + separacja narzędzi),
- wyjście: walidacja i safe-rendering (insecure output handling),
- ochrona przed DoS (limity tokenów, limity narzędzi, limity iteracji agentów),
- supply chain: nie tylko paczki (SBOM), ale też modele, prompty, dane, retrieval sources. <sup>7</sup>

Twoje SBOM-podejście jest świetnym szkieletem: przenieś je na „SBOM dla modelu” (model card + data lineage + wersje promptów + narzędzia).

Zbuduj plan post-market monitoring w stylu AI Act/NIST jako artefakt repozytoryjny. Nie chodzi o zgodność legalną „na papierze”, tylko o spójne sterowanie: KPI, progi, odpowiedzialności, mechanizmy reagowania i retencja danych. NIST AI RMF i jego profile są dobrym językiem, żeby to uporządkować (Govern/Map/Measure/Manage). <sup>28</sup> AI Act wymusza systematyczność i „monitowanie w czasie” – warto to potraktować jako architekturę, nie compliance. <sup>19</sup>

## Rekomendacje komunikacyjne

Zamień „metafory” na publiczny język sterowania: progi, pomiary, SLA, zasady degradacji. Rynek (Bain) mówi, że pricing AI bez telemetrii jest niewykonalny, a Reuters pokazuje, że inwestorzy rozliczają firmy z tego, czy rozumieją własną ekspozycję na disruption. <sup>29</sup> Komunikacyjnie warto więc mówić: jakie są liczniki (u), jakie są progi (u\*), co robisz przy przekroczeniu (degrade, cap, human-in-the-loop).

Przygotuj narrację „Data Act zmienia lock-in”: mniej egress, więcej interoperacyjności i semantyki. W Polsce można to spinać komunikacyjnie także źródłami publicznymi (gov.pl), żeby pokazać, że „koszt migracji” przestaje być tylko kwestią cennika, a staje się kwestią architektury. <sup>30</sup>

Włącz jasny rejestr ryzyk AI (security/ethics/cost) i politykę wyjątków. Twoje repozytoria SBOM dobrze rozumieją wyjątki jako element sterowania (wyjątek ma właściciela, expiry, widoczność). Ten wzorzec przenieś na AI: wyjątki od limitów, od polityk danych, od zasad output-handling powinny być mierzalne (inaczej stają się „mnożeniem logik”).

## Priorytetowe źródła cytowań i dlaczego są kluczowe

Najwyższy priorytet (bo definiują „ramę realności” i obowiązki):

- `Entity["organization","European Commission","eu executive body"]` / tekst AI Act i narzędzia Komisji (wymóg monitoringu/logów i cyklu życia) <sup>10</sup>
- `Entity["organization","Ministerstwo Cyfryzacji","warsaw, poland"]` (polskie ujęcie Data Act, w tym zniesienie opłat za zmianę dostawcy od 12.01.2027) <sup>31</sup>
- `Entity["organization","NIST","us standards institute"]` AI RMF 1.0 + profil GenAI (język zarządzania ryzykiem: govern/map/measure/manage) <sup>28</sup>
- `Entity["organization","OWASP Foundation","security nonprofit"]` Top 10 LLM Apps (najbardziej praktyczna lista ryzyk aplikacyjnych LLM) <sup>7</sup>

Wysoki priorytet (bo tłumaczą „dlaczego system się wywraca”):

- `Entity["organization","Google","tech company"]` SRE: cascading failures i overload/load shedding (operacyjna fizyka awarii) <sup>14</sup>
- `Entity["organization","International Energy Agency","intergovernmental energy org"]`: energia jako constraint skalowania AI/data centers <sup>32</sup>

- Reuters-strumień lutego 2026: materializacja „AI disruption” w wycenach i ryzyku kredytowym

18

Priorytet uzupełniający (bo przenoszą problem na „ekonomię i operacje”):

- Entity[\"organization\", \"FinOps Foundation\", \"finops.org\"] + FOCUS spec (język kosztu i wartości w wielu scope'ach, w tym AI i SaaS) <sup>33</sup>
- Entity[\"organization\", \"Bain & Company\", \"management consulting firm\"] : telemetria jako warunek transformacji pricingu SaaS pod AI <sup>3</sup>
- Entity[\"organization\", \"Urząd Ochrony Danych Osobowych\", \"warsaw, poland\"] : sygnał polskiego kontekstu ochrony danych w zastosowaniach AI (szczególnie, gdy AI wchodzi w HR/biometrię) <sup>34</sup>

## Diagram: gdzie Twoje „pętle” spotykają się z pętlami rynkowymi

flowchart TB

```

A[Agentowe użycie AI rośnie] --> B[Zużycie: tokeny/czas/narzędzia rośnie]
B --> C[Koszt zmienny q.u rośnie]
C --> D[Presja na pricing/capy/limity]
D --> A

B --> E[Ryzyko overload/kaskad]
E --> F[Rate limit + load shedding + circuit breaker]
F --> B

G[SBOM/scan/delta] --> H[Gate: progi]
H --> I[Decyzja: GO/STOP/mitigacja]
I --> G

J[Logi + pamięć kontekstu] --> K[Post-market monitoring]
K --> J

```

Ten diagram jest jednym zdaniem: Twoje repozytoria już mają dwa silne „hamulce” (SBOM-gate i mesh-gate), ale brakuje trzeciego hamulca, który dziś najbardziej boli SaaS+AI: **runtime-telemetrii ekonomicznej** i bramek sterowania kosztem/zużyciem per workflow/tenant. To jest dokładnie miejsce, gdzie Twoja teza o „pętli w pętli” może przestać być opisem, a stać się mechanizmem sterowania.

<sup>1</sup> <sup>18</sup> <https://www.investing.com/news/stock-market-news/us-software-stocks-tumble-sparks-concerns-that-ai-trade-is-reshaping-markets-4493058>

<https://www.investing.com/news/stock-market-news/us-software-stocks-tumble-sparks-concerns-that-ai-trade-is-reshaping-markets-4493058>

<sup>2</sup> <https://www.reuters.com/business/finance/ailed-software-selloff-may-pose-risk-15-trillion-us-credit-market-says-morgan-2026-02-10/>

<https://www.reuters.com/business/finance/ailed-software-selloff-may-pose-risk-15-trillion-us-credit-market-says-morgan-2026-02-10/>

<sup>3</sup> <sup>29</sup> <https://www.bain.com/insights/per-seat-software-pricing-isnt-dead-but-new-models-are-gaining-steam/>

<https://www.bain.com/insights/per-seat-software-pricing-isnt-dead-but-new-models-are-gaining-steam/>

- 4 <https://www.businessinsider.com/inference-whales-threaten-ai-coding-startups-business-model-2025-8>  
<https://www.businessinsider.com/inference-whales-threaten-ai-coding-startups-business-model-2025-8>
- 5 32 <https://www.iea.org/reports/energy-and-ai/energy-demand-from-ai>  
<https://www.iea.org/reports/energy-and-ai/energy-demand-from-ai>
- 6 <https://www.reuters.com/technology/artificial-intelligence/global-trade-war-may-produce-headwinds-nascent-ai-sector-iea-says-2025-04-10/>  
<https://www.reuters.com/technology/artificial-intelligence/global-trade-war-may-produce-headwinds-nascent-ai-sector-iea-says-2025-04-10/>
- 7 <https://owasp.org/www-project-top-10-for-large-language-model-applications/>  
<https://owasp.org/www-project-top-10-for-large-language-model-applications/>
- 8 28 <https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-ai-rmf-10>  
<https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-ai-rmf-10>
- 9 <https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-generative-artificial-intelligence>  
<https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-generative-artificial-intelligence>
- 10 19 <https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-72>  
<https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-72>
- 11 <https://digital-strategy.ec.europa.eu/en/policies/data-act-explained>  
<https://digital-strategy.ec.europa.eu/en/policies/data-act-explained>
- 12 21 [https://www.envoyproxy.io/docs/envoy/latest/api-v3/extensions/filters/http/ratelimit/v3/rate\\_limit.proto](https://www.envoyproxy.io/docs/envoy/latest/api-v3/extensions/filters/http/ratelimit/v3/rate_limit.proto)  
[https://www.envoyproxy.io/docs/envoy/latest/api-v3/extensions/filters/http/ratelimit/v3/rate\\_limit.proto](https://www.envoyproxy.io/docs/envoy/latest/api-v3/extensions/filters/http/ratelimit/v3/rate_limit.proto)
- 13 <https://preliminary.istio.io/latest/docs/reference/config/networking/destination-rule/>  
<https://preliminary.istio.io/latest/docs/reference/config/networking/destination-rule/>
- 14 22 <https://sre.google/sre-book/addressing-cascading-failures/>  
<https://sre.google/sre-book/addressing-cascading-failures/>
- 15 20 23 <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>  
<https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>
- 16 24 <https://sociology.stanford.edu/publications/threshold-models-collective-behavior>  
<https://sociology.stanford.edu/publications/threshold-models-collective-behavior>
- 17 <https://pubmed.ncbi.nlm.nih.gov/16578874/>  
<https://pubmed.ncbi.nlm.nih.gov/16578874/>
- 25 27 33 <https://focus.finops.org/what-is-focus/>  
<https://focus.finops.org/what-is-focus/>
- 26 <https://www.finops.org/insights/2025-finops-framework/>  
<https://www.finops.org/insights/2025-finops-framework/>
- 30 31 <https://www.gov.pl/web/cyfryzacja/akt-w-sprawie-danych---nowe-zasady-wymiany-danych>  
<https://www.gov.pl/web/cyfryzacja/akt-w-sprawie-danych---nowe-zasady-wymiany-danych>
- 34 <https://uodo.gov.pl/pl/589/3207>  
<https://uodo.gov.pl/pl/589/3207>