

Synteza repozytoriów DonkeyJLove z ocenami ryzyk SaaS+AI i testem hipotez asymetrii

Potrzeby informacyjne

Aby rygorystycznie odpowiedzieć na pytanie o „asymetrię” Twojej platformy względem problemów SaaS+AI (przy braku ograniczeń budżetowych/czasowych jako założeniu roboczym), muszę ustalić:

- Jak **mechanizmy sterowania, odporności i redukcji złożoności** są rzeczywiście zaimplementowane w kodzie/specyfikacjach (a nie tylko postulowane) i gdzie dokładnie.
- Jak te mechanizmy mapują się na **aktualne, publiczne osie krytyki** SaaS+AI: koszty i zmiana modeli cenowych, awarie/skalowalność, bezpieczeństwo (LLM+łańcuch dostaw), zgodność (AI Act), etyka i odpowiedzialność.
- Czy repozytoria **jawnie adresują** te ryzyka (testowalnie, mierzalnie), czy tylko „pasują narracyjnie”.
- Jak zdefiniować **metryki asymetrii** (korzyść/ryzyko/czas/koszt) i jakie dane są potrzebne do **falsyfikacji** hipotez (panelowo i Monte Carlo).
- Jak są **luki i sprzeczności** techniczne (np. brak kontroli dostępu, brak telemetryki kosztu LLM, słabe domknięcia pętli) oraz jak je naprawić technicznie i komunikacyjnie.
- Jak ułożyć **mapę zależności ryzyk (kaskad)** tak, by dało się ją udostępnić jako jeden spójny artefakt (esej + tabela + diagramy).

Streszczenie wykonawcze

Twoje repozytoria tworzą spójną propozycję „anty-SaaS” rozumianą jako **platforma sterowania złożonością**: pomiar → próg → akcja, domykany tożsamością bytu (AID), pamięcią zdarzeń i bramkami (gate), a po stronie runtime’u – mechaniką **odporności na kaskady** (rate limiting, circuit breaking, outlier ejection) oraz – na poziomie poznawczym/organizacyjnym – protokołami kontekstu i mapą 9D (QV9D/HMK9D). W kodzie widać realne elementy sterowania (np. „koperta zdarzenia” AID i kanał zdarzeń sbom/scan/delta/gate) oraz realne elementy amortyzacji awarii (fail-closed rate limit, outlierDetection). ¹ ² ³

Z perspektywy zewnętrznych ocen (NIST ⁴, AI Act, OWASP Foundation ⁵, FinOps Foundation ⁶ / FOCUS, International Energy Agency ⁷, Reuters ⁸, Identity[“company”,“Bain & Company”,“management consulting”]) Twoje podejście **dobrze pokrywa** trzy klasy ryzyk: (a) obserwowalność i dowodowość (logowanie, ślad decyzji, identyfikowalność bytu), (b) łańcuch dostaw i kontrola zmian (SBOM+delta+gate), (c) odporność na przeciążenia i kaskady na warstwie infrastrukturalnej (rate limit/circuit breaker). ⁹

Największe zidentyfikowane luki względem współczesnej krytyki SaaS+AI są dwie:

- **Brak “twardej” ekonomiki kosztu inferencji** (telemetria kosztu per funkcja/per klient/per agent, budżety, unit cost, automatyka ograniczeń) – przy czym zewnętrzne źródła pokazują, że ogon kosztu (tzw. „inference whales”) potrafi zjeść marżę i wymusić zmianę pricingu. ¹⁰
- **Brak formalnego domknięcia wymogów zgodności i bezpieczeństwa LLM** (np. prompt injection, output handling, kontrola danych wrażliwych) na poziomie checklist/testów i polityk – co jest rdzeniem OWASP Top 10 dla LLM aplikacji. ¹¹

W konsekwencji: Twoje repo przybliżają „asymetrię” jako **redukcję ryzyka systemowego i kaskad** przy rosnącej złożoności, ale nie falsyfikują jeszcze w pełni krytyki ekonomicznej (pricing/cost) ani bezpieczeństwa LLM (Top10) bez wdrożenia pomiarów i eksperymentów panelowych.

Materiały dowodowe z repozytoriów

Repozytorium SBOM jako aparat sterowania zmianą i ryzykiem

W `sbom` widać architekturę, w której SBOM nie jest raportem „do przeczytania”, tylko **czujnikiem** w pętli sterowania *pomiar* → *próg* → *akcja*. Jest to nazwane wprost w kontrakcie AID: AID ma spinać „artefakty obserwacji i sterowania” (SBOM, scan, delta, gate) w jedną tożsamość bytu i umożliwić korelację w czasie. ¹

Kluczowy fragment implementacyjno-pojęciowy to „koperta zdarzenia” (`@timestamp`, `event_type`, `aid{...}`, `payload{...}`), która jest minimalnym, przenośnym formatem do indeksowania i filtracji w narzędziach obserwowalności (Elastic/Splunk). To jest ważne dla asymetrii, bo w SaaS klasycznym często brakuje *jednej* spójnej osi identyfikacji bytu i decyzji (zamiast tego są rozproszone logi, metryki i ticketing). ¹²

W dokumentacji pipeline’u jest jawne rozdzielanie obserwacji na typy (`sbom`, `scan`, `delta`, `gate`) i wskazanie artefaktów `.lab_out/*` (SBOM CycloneDX, raport skanu, snapshot, delta, gate vars). To jest „fizyczna lista dowodów” potrzebna do sterowania zmianą i do audytu (kto, co i dlaczego zablokował). ¹³

Repozytorium swarm jako amortyzator kaskad runtime

W `swarm` znajdują się twarde mechanizmy infrastrukturalne, które wprost odpowiadają na ryzyko „kaskad” przez przeciążenia:

- **Rate limiting z trybem fail-closed** (`failure_mode_deny: true`) oraz timeoutem na usługę rate-limit (0.25s). To jest szczególnie istotne w kontekście AI, bo przeciążenia często mają charakter kosztowy i obliczeniowy (LLM DoS, runaway calls). Fail-closed działa jak *bezpiecznik*: w razie utraty kontroli nad komponentem limitującym nie „otwierasz bramy” na nieograniczony ruch. ²
- **Circuit breaking przez outlier detection** (wyrzucanie endpointów po serii 5xx, agresywne 100% ejection). To jest klasyczny mechanizm zatrzymania propagacji awarii poprzez izolację wadliwych instancji. ³

W warstwie aplikacyjnej `aggregator.py` pokazuje wzorzec „ingest → walidacja → forward”: odbiór UDP, dekodowanie z `errors='replace'` (nie wywalaj pętli na błędnych bajtach), parser JSON, a następnie forward HTTP do API. To jest drobny, ale realny detal asymetrii: w systemach kaskadowych często padają „meta-usługi” ingestujące dane; tu kod jest napisany tak, by nie wywracać się na błędzie dekodowania i by nie blokować pętli (wątki). ¹⁴

Jednocześnie `aggregator_api.py` ujawnia typową lukę: endpoint przyjmuje dane i zapisuje do DB, ale w widocznym fragmencie brak jest warstwy uwierzytelniania/autoryzacji (a to w SaaS+AI często jest źródłem incydentów). Jest minimalna walidacja pól i parametryzowane SQL (co akurat redukuje SQLi), ale nie rozwiązuje nadużyć/zalewu/poisoningu danych wejściowych. ¹⁵

Repozytorium chunk-chunk jako formalizacja kompresji i „energetyki” decyzji

W `hmk9d_protocol.yaml` (repo `chunk-chunk`) wprost zapisujesz kontrakt decyzyjny jako złożenie: $H(s) = g(F(s))$, gdzie `F` jest kompresją stanu do znaku, a `g` polityką decyzji. Dodatkowo pojawia się formalizacja ryzyka $R(F, g)$ i energii kroku $E(\Delta)$ oraz E_{total} . To jest punkt, w którym Twoja „asymetria” różni się od SaaS: SaaS zwykle modeluje system jako zestaw usług i SLA, a tu modelujesz go jako układ sterowania z kosztami lokalnymi i globalnymi oraz osiami (T,S,R,E,I,F,A,P,D). ¹⁶

To jest istotne również dlatego, że współczesna krytyka SaaS+AI przesuwając ciężar z „feature’ów” na **koszt i ryzyko agentowości**: długie trajektorie, rekurencja, rosnące tokeny, rosnący koszt (wprost OWASP LLM04). Kontrakt HMK9D jest semantycznym szkieletem, który *da się* podpiąć pod instrumentację kosztu/ryzyka (choć w repo brak jeszcze gotowej metryki pieniężnej). ¹⁷

Repozytoria ai_platform i HA2D jako warstwa mapowania i pamięci

`ai_platform/platform.md` definiuje mapowanie logicznego woluminu `/QV9D` na fizyczną strukturę kodu i repozytoriów: INF/SEM/MAND + mosty + typ artefaktu (SPEC/STATE/METRICS/RITUAL/CI). To jest forma „metamodelu platformy”, która – jeśli jest utrzymywana operacyjnie – redukuje koszt koordynacji i drift semantyczny między modułami. To jest też sposób na to, by „złożoność” była indeksowalna (współrzędne), a nie tylko opisywana. ¹⁸

`LAT_GLX_PROJECT_MOSAIC.MD` wiąże repozytoria rolami w obrębie całości (chunk-chunk jako rdzeń, swarm jako warstwa rojowa, HA2D jako brama Human-AI, writeups jako kronika). To jest ważne, bo asymetria często jest w praktyce „architekturą organizacyjną”: kto odpowiada za co i jak to się składa w system-of-systems. ¹⁹

W `HA2D/context_protocol.md` pojawia się **Context Memory Manager**: rekordy mają `uuid`, `timestamp`, `payload` i `sha256` (integralność). To jest wzorzec przechodzenia od „ulotnej sesji AI” do artefaktów, które można audytować i odtwarzać – czyli dokładnie tego, czego wymagają współczesne reżimy zgodności i bezpieczeństwa (traceability, post-market monitoring). ²⁰

W `HA2D/readme.md` podkreślona jest rola cyklu życia (pętla generacyjna), modułów analitycznych i HUD jako jedynego interfejsu. To wzmacnia tezę o asymetrii: interfejs ma być „sterownikiem”, nie tylko UI. ²¹

Repozytorium writeups jako empiryczna rama „protokołów kontekstu”

W `protokoły_kontekstu_chunk-chunk_facebook_case.md` opisujesz trzy poziomy interakcji: HUMAN-AI, AI-HUMAN, AI-AI oraz proponujesz formalizację „protokołu kontekstu” jako aktualizacji stanu i funkcji decyzji, z możliwością falsyfikacji poprzez porównanie do klasyfikatora bazowego i stabilność predykcji (out-of-sample). To jest ważne, bo przenosi dyskusję o ryzykach AI z poziomu „wrażenia” na poziom *mierzalnych zależności wejście→akcja*. ²²

Konfrontacja z ocenami zewnętrznymi ryzyk SaaS+AI

Ekonomia i pricing jako rdzeń ryzyka SaaS+AI

Współczesna krytyka SaaS+AI bardzo często nie zaczyna się od „AI jest niebezpieczne”, tylko od „AI zmienia strukturę kosztu i wartości, więc rozsądza pricing i przewidywalność marży”. Anthropic ²³ i inni dostawcy agentów uruchomili falę rynkowej niepewności, widoczną w doniesieniach o globalnych

wyprzedażach spółek software/data services po demonstracjach narzędzi automatyzujących pracę (lęk o przechwycenie wartości z tradycyjnego software i usług). ²⁴

W warstwie mikroekonomicznej, zjawisko „inference whales” pokazuje ogon kosztu: niewielka grupa użytkowników może generować koszty inferencji wielokrotnie przekraczające abonament, co wymusza limity i zmianę modeli cenowych. ²⁵ To bezpośrednio łączy się z OWASP LLM04 (Model Denial of Service), gdzie „atak” może być po prostu ekonomicznym przeciążeniem zasobów przez ciężkie zapytania. ¹⁷

Bain opisuje, że odejście od per-seat w stronę usage/output/outcome jest trudne, bo wymaga telemetryki produktu, przebudowy billing/finance i „wspólnego języka” metryk między zespołami. ²⁶ To jest dokładnie obszar, którego Twoje repozytoria jeszcze nie domykają operacyjnie: masz język mostów/energii (HMK9D), ale nie masz jeszcze warstwy metryki kosztu pieniężnego i integracji billing.

Energetyka i infrastruktura jako twarde ograniczenie

International Energy Agency ⁷ wskazuje, że zużycie energii elektrycznej przez data centers ma rosnąć szybko, a w scenariuszu bazowym globalnie ok. się podwoić do ~945 TWh do 2030 r., z dużą niepewnością i silną koncentracją lokalną (lokalne bottlenecks). ²⁷ Ta perspektywa wzmacnia Twoją oś „Semantyka-Energia”: energia nie jest już metaforą – staje się realnym ograniczeniem kosztowym i regulacyjnym.

To jest też miejsce na Twoje pytanie o „różne ceny prądu dla warstw klastra”: dywersyfikacja kosztu energii *może* obniżyć korelację szoków kosztowych, ale nie usuwa kaskad wynikających z przeciążeń, vendor lock-in, ani ogona kosztu inferencji. W modelach fazowych jest to redukcja sprzężenia jednego parametru (koszt energii), nie likwidacja dodatkich sprzężeń w całym systemie (popyt→koszt→limity→spadek jakości, itd.). ²⁸

Zgodność, logowanie i post-market monitoring

AI Act wprost wymaga, by systemy wysokiego ryzyka umożliwiały **automatyczne logowanie zdarzeń przez cały cykl życia**, w zakresie adekwatnym do celu, oraz by logi wspierały identyfikację sytuacji ryzykownych i post-market monitoring. ²⁹ Dodatkowo art. 72 nakłada obowiązek systemu post-market monitoring i planu, a także zapowiada template Komisji do 2 lutego 2026. ³⁰ (W polskim komunikacie rządowym widać etapowe wejście w życie przepisów i nacisk na bezpieczeństwo oraz kompetencje). ³¹

Twoje repozytoria są do tego „naturalnie zestrojone” na poziomie formy danych: AID + koperta zdarzenia + pamięć kontekstu z SHA256 to kompatybilny kierunek, bo tworzy weryfikowalny ślad decyzji i stanu. ¹² ²⁰ Brakuje natomiast jawnego powiązania: **jakie zdarzenia są „relevant events”**, jaka jest retencja, jak wygląda pipeline post-market monitoring i jak są zarządzane „substantial modifications” (język AI Act). To jest luka dokumentacyjno-proceduralna, nie tylko kodowa. ³²

Bezpieczeństwo LLM i łańcuch dostaw

OWASP Top 10 dla aplikacji LLM wskazuje m.in. prompt injection, insecure output handling, model DoS, supply chain vulnerabilities i leakage danych wrażliwych. ¹¹ Twoje repo `sbom` adresuje **supply chain** w klasycznym sensie (SBOM, delta, scan, gate), a `swarm` adresuje **DoS/overload** przez rate limiting i circuit breaker. ¹³ ²

Jednak OWASP Top 10 dla LLM obejmuje również klasy ryzyk typowe dla agentów (prompt injection i output handling), które nie są widoczne jako kompletne polityki/testy w analizowanych fragmentach kodu. To oznacza, że Twoje repo są obecnie asymetryczne głównie w domenie **inżynierii systemów i obserwowalności**, a słabiej w domenie **bezpieczeństwa semantycznego LLM na wejściu/wyjściu**.

11

Ryzyko lock-in i koszty migracji

Z polskich źródeł (Ministerstwo Cyfryzacji, PARP) wynika, że Data Act ma ułatwiać zmianę dostawcy chmurowego i wygasić opłaty za switching od 12 stycznia 2027 r. Ministerstwo Cyfryzacji ³³ ³⁴ To jest „zewnętrzny wektor asymetrii”: platformy, które budują koszt/ryzyko w sposób przejrzysty i przenośny (np. standardy danych, kompatybilne logi, identyfikowalność), będą miały przewagę w świecie, gdzie migracje są tańsze i częstsze.

Twoje podejście (AID jako minimalny kontrakt + event envelope) jest kompatybilne z tą presją, ale brakuje jawnego planu: jak przenosić telemetrykę, jak normalizować koszty (tu pojawia się FinOps/FOCUS) i jak uciec od vendor-specific silosów obserwowalności. ¹ ³⁵

Falsyfikacja hipotez asymetrii i projekt testów

Hipotezy asymetrii

W „absolutnym reżimie naukowym” hipotezy muszą być falsyfikowalne. Proponuję trzy hipotezy, które są zgodne z Twoją architekturą i jednocześnie testują to, co media/eksperci krytykują:

H1: Asymetria kosztowo-awaryjna (ogon kosztu i przeciążenia).

Platforma redukuje *prawdopodobieństwo wejścia w stan kaskadowy* (outage, runaway cost, degradacja jakości) przy tym samym obciążeniu lub tej samej klasie zadań AI, w porównaniu do wdrożenia „SaaS-na-skrót”.

Uzasadnienie: fail-closed rate limit + circuit breaker + bramki + separacja ingest. ² ³ ³⁶

H2: Asymetria dowodowo-zgodnościowa (traceability).

Platforma zwiększa „dowodowość” działania systemu AI (kto/co/kiedy/z jaką tożsamością) i skraca czas dojścia do przyczyny (MTTR) w incydentach, w porównaniu do systemu bez AID/koperty zdarzeń/pamięci kontekstu.

Uzasadnienie: AID + event envelope + SHA256 kontekstu jako podstawy logów i rekonstrukcji. ¹² ²⁰

32

H3: Asymetria złożonościowa (kompresja i sterowanie).

Platforma zmniejsza liczbę „niezależnych logik” potrzebnych do sterowania systemem (redukcja entropii sterowania) poprzez formalny kontrakt $H(s)=g(F(s))$ i mapę QV9D, co obniża częstość błędów organizacyjnych (np. błędne ownership, błędne zależności procesów).

Uzasadnienie: HMK9D + QV9D mapowanie repo/modułów. ¹⁶ ¹⁸

Metryki i dane wejściowe

Dla H1 (koszt/awarie):

- **Cost tail index**: udział kosztu generowany przez top 1% (lub 0.1%) klientów/zapytań/agentów (analog „inference whales”).

- **Runaway rate**: odsetek runów agentowych przekraczających budżet tokenów/czasu.

- **SLO breach rate**: liczba naruszeń latency/availability na 10k requestów.
- **Economic DoS proxy**: (koszt / czas) per request; wykrywanie anomalii.

Dla H2 (dowody/MTTR):

- **Trace completeness**: % zdarzeń z kompletnym kluczem tożsamości (AID) i korelacją do decyzji gate.
- **Mean time to explain**: czas do poprawnej rekonstrukcji „dlaczego system zrobił X”.
- **Auditability score**: możliwość odtworzenia sekwencji decyzji na podstawie logów i rekordów kontekstu.

Dla H3 (złożoność):

- **Coordination entropy**: liczba wyjątków ownership/nieprzypisanych alertów, liczba ręcznych eskalacji bez mapowania QV9D.
- **Change amplification factor**: ile komponentów dotyka przeciętna zmiana (delta) vs ile decyzji/akcji wywołuje.

Projekt testu panelowego

Jeżeli masz wiele projektów/usług (panel), najczystszy schemat to:

- grupa „treatment”: usługi używające pełnego stosu (AID + event envelope + SBOM/delta/gate + rate limit/circuit breaker + telemetryka kosztu),
- grupa „control”: porównywalne usługi bez tych mechanizmów lub z klasycznym SaaS pattern.

Model minimalny: panel z efektami stałymi (usługa i czas), outcome’y: SLO breach rate, MTTR, cost tail index. Kluczowe jest, że zewnętrzne źródła mówią o narastającej presji kosztowej i zmianie prycingu; panel ma pokazać, czy Twoja architektura zmienia nachylenie tych krzywych w czasie. ³⁷

Symulacja Monte Carlo jako falsyfikacja bez danych produkcyjnych

Jeśli nie masz jeszcze telemetryki kosztu, można przeprowadzić falsyfikację „wstępną” przez symulację obciążeń z ciężkim ogonem (co jest spójne z obserwacjami rynku o inference whales). ²⁵

Poniżej: przykładowa symulacja rozkładu kosztu (lognormalnie ciężki ogon) i koncentracji kosztów (krzywa Lorenza). To nie jest dowód empiryczny o Twoim systemie, ale jest **testem mechanizmu**: jeśli ogon jest ciężki, brak instrumentacji i limitów musi prowadzić do kryzysów prycingu lub jakości.

Ogon kosztu inferencji: koncentracja kosztów (symulacja)

W tej symulacji top 1% użytkowników generuje ok. 21% kosztu (typowy wzorec „whales”). W realnym systemie falsyfikacja H1 polega na sprawdzeniu, czy po wdrożeniu mechanizmów z **swarm** i warstwy budżetów (której jeszcze brakuje) ogon kosztu *przestaje* wymuszać spadek jakości lub zmianę prycingu.

Diagram mechaniczny: pętla sterowania i miejsca „asymetrii”

flowchart LR

A[Pomiar: SBOM/SCAN/DELTA] --> B[Tożsamość bytu: AID + koperta zdarzeń]

B --> C[Pamięć: indeks zdarzeń + kontekst]

C --> D[Próg: gate / polityki / limity]

D --> E[Akcja: blokada / ticket / rollout / throttle]

E --> A

```

subgraph Runtime amortyzacja
  R1[Rate limiting fail-closed] --> R2[Circuit breaker / outlier ejection]
end

E --> Runtime amortyzacja

```

Ten diagram jest "mechaniczny" w sensie cybernetycznym: pokazuje, gdzie domykasz pętlę (tożsamość→pamięć→próg→akcja). AID i gate są tu Twoim rdzeniem asymetrii względem klasycznego SaaS. 1 2 38

Luki, niezgodności i rekomendacje

Główne luki względem krytyki SaaS+AI

Luka kosztowa (najbardziej krytyczna): brak telemetrii i sterowania kosztem inferencji.

Źródła z rynku wskazują, że bez instrumentacji i limitów „whales” wymuszają limity i zmianę prycingu. 39

W Twoich repo widać język „energii” (HMK9D) i mechanizmy runtime (rate limit), ale nie widać jeszcze pomostu: koszt per request/per tenant/per agent, budżety, chargeback/showback i automatyczne reguły zatrzymania w oparciu o koszt (FinOps/FOCUS). 16 40

Luka bezpieczeństwa LLM na wejściu/wyjściu (OWASP Top 10):

Masz mocne elementy supply-chain (SBOM) i częściowo DoS (rate limiting), ale brakuje widocznego, kompletnego „policy stack” dla prompt injection/output handling/sensitive data disclosure. 11

Luka zgodności AI Act jako procesu (nie tylko logów):

AI Act wymaga logowania i post-market monitoring; w repo widać format danych (AID, kontekst), ale nie widać kompletnego procesu: klasy zdarzeń, retencja, review, aktualizacja planu monitoringu. 41

Luka security-by-default w mikroserwisach:

`aggregator_api.py` w pokazanym fragmencie ma minimalną walidację, ale brak warstwy authn/authz – co w SaaS jest częstą przyczyną nadużyć i „kosztowych DoS” (zalew danych → koszty DB/IO). 15

Rekomendacje techniczne

Najkrócej: musisz domknąć „Semantyka–Energia” w pieniądzu i w polityce.

- Zaimplementuj **telemetrię kosztu AI** jako pierwszorzędny strumień zdarzeń (obok sbom/scan/delta/gate): `ai_usage_event` z AID + tenant + model + tokens_in/out + latency + koszt szacowany + quota/budget state. To jest warunek, by przejść na hybrydowe modele cenowe opisane przez Bain i by obronić się przed „whales”. 42 12
- Użyj **FinOps Scopes** (SaaS + Public Cloud + „AI”) i FOCUS 1.3 jako formatu kosztów/zużycia, aby koszty były przenośne, audytowalne i gotowe na presję Data Act/switching. 43
- Rozszerz mechanizmy `swarm` o budżety i „policy throttling” zorientowane na koszt: rate limit nie tylko QPS, ale QPS *ważony* kosztem (np. token-em koszt). OWASP LLM04 opisuje DoS także jako kosztowy/zasobowy. 17
- Zbuduj zestaw testów/polityk dla OWASP Top10 LLM (minimum: prompt injection, output handling, data leakage) i włącz to jako osobny „gate” w Twojej pętli. 44

- Uczyń warstwę API (np. `aggregator_api`) „secure-by-default”: authn/authz, rate limit per klient, walidacja schematu, limity rozmiaru payload, obserwowalność nadużyć. ¹⁵
- Dla zgodności: przygotuj „szablon post-market monitoring” zgodny z AI Act (art. 72) jako artefakt platformy, a logowanie „relevant events” (art. 12) powiąż bezpośrednio z AID i z cyklem wersji. ³² ¹

Rekomendacje komunikacyjne

- Przetwórz narrację z „AI platforma / anty-SaaS” na „**system sterowania ryzykiem i kosztem AI w pętli dowodowej**”. To lepiej odpowiada na język regulatora (logi, monitoring), na język FinOps (unit cost, showback), i na język rynku (przewidywalność marży przy ogonie kosztu). ⁴⁵
- W komunikacji z odbiorcami biznesowymi używaj „jednego zdania wartości”: *redukujemy prawdopodobieństwo kaskady kosztowej i awaryjnej poprzez instrumentację + progi + automatyczne akcje*. To jest dokładnie to, co media i inwestorzy adresują, obserwując paniki rynkowe wokół AI-disruption. ⁴⁶

Tabela porównawcza: fragmenty kodu vs oceny mediów/ekspertów

Repo / fragment	Mechanizm asymetrii (co robi)	Ryzyko/ocena zewnętrzna	Zgodność z krytyką	Luka / co dodać
<code>sbom/AID_CONTRACT.md</code>	Tożsamość bytu (AID) + koperta zdarzeń = korelacja decyzji i ryzyka w czasie ¹²	AI Act: logowanie i traceability; NIST AI RMF: zarządzanie ryzykiem w cyklu życia ⁴⁷	Wysoka (kierunek)	Dopisać: klasy “relevant events”, retencję, plan post-market monitoring
<code>sbom/docs/03_JENKINS_PIPELINE.md</code>	Strumień sbom/scan/delta/gate + artefakty <code>.lab_out</code> = dowód zmian i bramkowanie ¹³	NIST SSDF: praktyki SDLC; OWASP supply chain ⁴⁸	Średnia-wysoka	Dodać: VEX/ attestations i automatyczne policy gates
<code>swarm/.../rate-limit.yaml</code>	Fail-closed rate limit + timeout = bezpiecznik przeciw przeciążeniom ²	OWASP LLM04 (Model DoS) + ryzyko “inference whales” ³⁶	Wysoka (na runtime)	Rozszerzyć na limity kosztowe per tenant/ model

Repo / fragment	Mechanizm asymetrii (co robi)	Ryzyko/ocena zewnętrzna	Zgodność z krytyką	Luka / co dodać
<code>swarm/.../circuit-breaker.yaml</code>	Outlier detection i ejection = hamulec kaskad 5xx ³	Media: rosnąca obawa o awarie/ skalowalność i utratę przewagi software ⁴⁹	Średnia	Uzupełnić o SLO-driven autoscaling i testy chaosowe
<code>swarm/aggregator/aggregator.py</code>	Odporność ingest (decode replace, nieblokowanie pętli) ¹⁴	OWASP LLM04: rekurencja/ rozrost pracy jako forma DoS ¹⁷	Średnia	Dodać: backpressure, kolejki, limity payload
<code>swarm/aggregator-api/aggregator_api.py</code>	Minimalna walidacja pól + zapis do DB ¹⁵	OWASP: nadużycia, data poisoning, brak kontroli dostępu ⁴⁴	Niska	Authn/authz, schema validation, rate limit + abuse detection
<code>chunk-chunk/hmk9d_protocol.yaml</code>	Formalizacja H(s)=g(F(s)), osie 9D, energia i ryzyko ¹⁶	NIST AI RMF (GAI profile): potrzeba profili ryzyka i mierników w cyklu ³⁸	Średnia (model)	Zmapować "energia" na realny koszt (tokens/PLN/kWh) i dołączyć testy
<code>ai_platform/platform.md</code>	QV9D jako mapa systemu (INF/ SEM/MAND + mosty + artefakty) ¹⁸	Bain: potrzeba wspólnego języka metryk (telemetry, pricing) ²⁶	Średnia	Zmaterializować: narzędzia do automatycznego tagowania danych i kosztów w QV9D
<code>HA2D/context_protocol.md</code>	Pamięć kontekstu (uuid/timestamp/ sha256) = integralność i rekonstrukcja ²⁰	AI Act: logi i monitoring; NIST: traceability i governance ⁵⁰	Wysoka (kierunek)	Polityki prywatności, retencja, minimalizacja danych, audyt dostępu

Repo / fragment	Mechanizm asymetrii (co robi)	Ryzyko/ocena zewnętrzna	Zgodność z krytyką	Luka / co dodać
<code>writeups/...facebook_case.md</code>	Empiryczna falsyfikowalność "protokołu kontekstu" (model czarnej skrzynki) ²²	Deбата publiczna: systemy AI jako nieprzejrzyste, wymagające audytu ⁵¹	Średnia	Ustandaryzować jako procedurę testów i raportowania (nie tylko narracja)

Źródła priorytetowe

Najważniejsze źródła (w kolejności "nośności" dla tez o ryzykach i asymetrii):

- NIST ⁴ : AI RMF 1.0 i profil dla GAI – podstawowy język ryzyk i cyklu życia. ⁵²
- AI Act (art. 12 i 72) + polski komunikat o wejściu w życie: logowanie, post-market monitoring, wymagania procesu. ⁴¹
- OWASP Foundation ⁵ : Top 10 dla LLM aplikacji i LLM04 Model DoS – mapa praktycznych ryzyk. ¹¹
- FinOps Foundation ⁶ : Framework 2025 (Scopes) oraz FOCUS 1.3 – normalizacja kosztu i telemetriki (warunek przejścia na nowe modele cenowe). ⁵³
- International Energy Agency ⁷ : „Energy and AI” – twardy constraint energetyczny dla AI. ²⁷
- Reuters ⁸ : obserwacje rynkowe o AI-disruption jako czynnika wycen i „panik” sektorowych. ⁴⁶
- [Entity["company","Bain & Company","management consulting"]]: zmiana prycingu i konieczność telemetriki/organizacyjnego języka metryk. ²⁶
- „Inference whales” jako empiryczna presja na prycing w usługach AI. ²⁵
- Polska perspektywa Data Act (switching fees 2027): presja na przenośność i transparentność chmury/SaaS. ⁵⁴

¹² AID_CONTRACT.md

https://github.com/DonkeyJLove/sbom/blob/77fbb61e4d583ff4f91cce8c06cdc61e31201c96/AID_CONTRACT.md

² ⁶ infrastructure/istio/policies/rate-limit.yaml

<https://github.com/DonkeyJLove/swarm/blob/1fe5867fa749f376826621d6b66c0597d569bce0/infrastructure/istio/policies/rate-limit.yaml>

³ infrastructure/istio/policies/circuit-breaker.yaml

<https://github.com/DonkeyJLove/swarm/blob/1fe5867fa749f376826621d6b66c0597d569bce0/infrastructure/istio/policies/circuit-breaker.yaml>

⁵ ²⁷ ²⁸ <https://www.iea.org/reports/energy-and-ai/energy-demand-from-ai>

<https://www.iea.org/reports/energy-and-ai/energy-demand-from-ai>

⁷ ³⁴ ⁵⁴ <https://www.gov.pl/web/cyfryzacja/akt-w-sprawie-danych---nowe-zasady-wymiany-danych>

<https://www.gov.pl/web/cyfryzacja/akt-w-sprawie-danych---nowe-zasady-wymiany-danych>

⁸ ¹⁷ ³⁶ <https://genai.owasp.org/llmrisk2023-24/llm04-model-denial-of-service/>

<https://genai.owasp.org/llmrisk2023-24/llm04-model-denial-of-service/>

⁹ ⁵² <https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-ai-rmf-10>

<https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-ai-rmf-10>

¹⁰ ²⁵ ³⁹ <https://www.businessinsider.com/inference-whales-threaten-ai-coding-startups-business-model-2025-8>

<https://www.businessinsider.com/inference-whales-threaten-ai-coding-startups-business-model-2025-8>

- 11 44 <https://owasp.org/www-project-top-10-for-large-language-model-applications/>
<https://owasp.org/www-project-top-10-for-large-language-model-applications/>
- 13 [docs/03_JENKINS_PIPELINE.md](https://github.com/DonkeyJLove/sbom/blob/77fbb61e4d583ff4f91cce8c06cdc61e31201c96/docs/03_JENKINS_PIPELINE.md)
https://github.com/DonkeyJLove/sbom/blob/77fbb61e4d583ff4f91cce8c06cdc61e31201c96/docs/03_JENKINS_PIPELINE.md
- 14 [agggregator/agggregator.py](https://github.com/DonkeyJLove/swarm/blob/1fe5867fa749f376826621d6b66c0597d569bce0/agggregator/agggregator.py)
<https://github.com/DonkeyJLove/swarm/blob/1fe5867fa749f376826621d6b66c0597d569bce0/agggregator/agggregator.py>
- 15 [agggregator-api/agggregator_api.py](https://github.com/DonkeyJLove/swarm/blob/1fe5867fa749f376826621d6b66c0597d569bce0/agggregator-api/agggregator_api.py)
https://github.com/DonkeyJLove/swarm/blob/1fe5867fa749f376826621d6b66c0597d569bce0/agggregator-api/agggregator_api.py
- 16 [hmk9d_protocol.yaml](https://github.com/DonkeyJLove/chunk-chunk/blob/b71a1d69b912f3cb9d793ef433573fb7e77ae6e8/hmk9d_protocol.yaml)
https://github.com/DonkeyJLove/chunk-chunk/blob/b71a1d69b912f3cb9d793ef433573fb7e77ae6e8/hmk9d_protocol.yaml
- 18 [platform.md](https://github.com/DonkeyJLove/ai_platform/blob/75dea7b28dce9fa6f9e9e37aaa514c6e04330606/platform.md)
https://github.com/DonkeyJLove/ai_platform/blob/75dea7b28dce9fa6f9e9e37aaa514c6e04330606/platform.md
- 19 [LAT_GLX_PROJECT_MOSAIC.MD](https://github.com/DonkeyJLove/ai_platform/blob/75dea7b28dce9fa6f9e9e37aaa514c6e04330606/LAT_GLX_PROJECT_MOSAIC.MD)
https://github.com/DonkeyJLove/ai_platform/blob/75dea7b28dce9fa6f9e9e37aaa514c6e04330606/LAT_GLX_PROJECT_MOSAIC.MD
- 20 [context_protocol.md](https://github.com/DonkeyJLove/HA2D/blob/8b22ee8de388af3b9cf26365e1679cc6c356ef2a/context_protocol.md)
https://github.com/DonkeyJLove/HA2D/blob/8b22ee8de388af3b9cf26365e1679cc6c356ef2a/context_protocol.md
- 21 [readme.md](https://github.com/DonkeyJLove/HA2D/blob/8b22ee8de388af3b9cf26365e1679cc6c356ef2a/readme.md)
<https://github.com/DonkeyJLove/HA2D/blob/8b22ee8de388af3b9cf26365e1679cc6c356ef2a/readme.md>
- 22 [protokoly_kontekstu_chunk-facebook_case.md](https://github.com/DonkeyJLove/writeups/blob/dbb82ff3e26a618fc4c86da86c3ad94c3fba94a9/protokoly_kontekstu_chunk-facebook_case.md)
https://github.com/DonkeyJLove/writeups/blob/dbb82ff3e26a618fc4c86da86c3ad94c3fba94a9/protokoly_kontekstu_chunk-facebook_case.md
- 23 38 51 <https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-generative-artificial-intelligence>
<https://www.nist.gov/publications/artificial-intelligence-risk-management-framework-generative-artificial-intelligence>
- 24 46 49 <https://www.investing.com/news/stock-market-news/anthropics-new-ai-tools-deepen-selloff-in-data-analytics-and-software-stocks-investors-say-4483600>
<https://www.investing.com/news/stock-market-news/anthropics-new-ai-tools-deepen-selloff-in-data-analytics-and-software-stocks-investors-say-4483600>
- 26 37 42 <https://www.bain.com/insights/per-seat-software-pricing-isnt-dead-but-new-models-are-gaining-steam/>
<https://www.bain.com/insights/per-seat-software-pricing-isnt-dead-but-new-models-are-gaining-steam/>
- 29 32 41 45 47 50 <https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-12>
<https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-12>
- 30 <https://artificialintelligenceact.eu/article/72/>
<https://artificialintelligenceact.eu/article/72/>
- 31 <https://www.gov.pl/web/cyfryzacja/pierwsze-przepisy-rozporzadzenia-o-sztucznej-inteligencji-ai-act-zaczynaja-obowiazywac>
<https://www.gov.pl/web/cyfryzacja/pierwsze-przepisy-rozporzadzenia-o-sztucznej-inteligencji-ai-act-zaczynaja-obowiazywac>
- 33 35 40 <https://focus.finops.org/focus-specification/>
<https://focus.finops.org/focus-specification/>
- 43 53 <https://www.finops.org/insights/2025-finops-framework/>
<https://www.finops.org/insights/2025-finops-framework/>

⁴⁸ <https://csrc.nist.gov/Projects/ssdf>

<https://csrc.nist.gov/Projects/ssdf>